



Universidad Tecnológica de La Habana

“José Antonio Echeverría”

cujae

Facultad de Ingeniería Informática

Gemelo Digital Web para la Gestión Energética y Mantenimiento Predictivo de una Microrred Fotovoltaica Aislada

Autores:

Fabián Fernández Gálvez

Rubén Hernández Acevedo

Tutor:

Dr. C. Nayma Cepero Pérez

Ms. C. Ernesto Alberto Alvarez

La Habana, Cuba

Octubre, 2025

RESUMEN

La transición energética global ha puesto en evidencia las limitaciones de los sistemas eléctricos basados en combustibles fósiles, especialmente en territorios insulares y redes frágiles como las de Cuba, donde la dependencia del diésel y las restricciones de infraestructura se traducen en altos costos, vulnerabilidad ante eventos extremos y baja calidad del servicio. En este contexto, las microrredes fotovoltaicas con almacenamiento surgen como una alternativa estratégica para incrementar la resiliencia y reducir la huella de carbono, a la vez que permiten avanzar hacia esquemas de generación distribuida más eficientes y controlables. La CUJAE, como centro universitario y polo tecnológico, se encuentra en una posición privilegiada para experimentar con soluciones de microrredes inteligentes aplicadas tanto a su propio consumo como a escenarios de investigación y docencia. Sin embargo, la operación eficiente de una microrred fotovoltaica aislada exige herramientas capaces de integrar datos, modelos y visualización para apoyar decisiones en tiempo casi real. De esta necesidad surge el concepto de gemelo digital: una réplica virtual del sistema físico que, alimentada por datos operativos y modelos de simulación, permite monitorear el estado del sistema, anticipar comportamientos y evaluar estrategias de operación y mantenimiento. El presente trabajo articula estos conceptos transición energética, microrredes fotovoltaicas, gemelos digitales e inteligencia artificial en el desarrollo de un gemelo digital web para una microrred FV aislada vinculada al entorno universitario. La solución propuesta integra módulos de adquisición y gestión de datos, visualización web y modelos de aprendizaje automático para tres tareas clave: clasificación del estado de limpieza de paneles a partir de imágenes, predicción de generación fotovoltaica usando variables climáticas y estimación de patrones de consumo académico. El prototipo resultante demuestra la viabilidad de emplear un gemelo digital como plataforma unificada de monitoreo, predicción y soporte a la decisión, y sienta las bases para futuras extensiones hacia microrredes reales de mayor escala en la CUJAE y en el sistema eléctrico cubano.

Palabras clave: transición energética, microrred fotovoltaica, gemelo digital, inteligencia artificial, mantenimiento predictivo, predicción de generación, consumo energético.

ABSTRACT

The global energy transition has highlighted the limitations of fossil-fuel-based power systems, especially in islanded grids and fragile infrastructures such as those in Cuba, where diesel dependence and structural constraints result in high costs, vulnerability to extreme events and poor power quality. In this setting, photovoltaic microgrids with storage emerge as a strategic alternative to enhance resilience and reduce the carbon footprint, while enabling more efficient and controllable distributed generation schemes.

CUJAE, as a university and technological hub, is in a privileged position to experiment with smart microgrid solutions, both for its own electricity demand and for research and teaching scenarios. However, the efficient operation of an isolated PV microgrid requires tools capable of integrating data, models and visualization to support near real-time decision-making. This need is addressed by the concept of a digital twin: a virtual replica of the physical system that, fed by operational data and simulation models, enables system monitoring, behavior forecasting and the evaluation of operation and maintenance strategies.

This work brings together these concepts' energy transition, photovoltaic microgrids, digital twins and artificial intelligence through the development of a web-based digital twin for an isolated PV microgrid linked to the university environment. The proposed solution integrates data acquisition and management modules, a web visualization layer and machine learning models for three key tasks: classification of PV panel soiling from images, solar power forecasting based on meteorological variables, and estimation of university load patterns. The resulting prototype demonstrates the feasibility of using a digital twin as a unified platform for monitoring, forecasting and decision support, and lays the groundwork for future extensions towards larger-scale real microgrids at CUJAE and within the Cuban power system.

Keywords: energy transition, photovoltaic microgrid, digital twin, artificial intelligence, predictive maintenance, generation forecasting, energy consumption.

Índice

RESUMEN	2
ABSTRACT	2
Introducción.....	8
Capítulo 1. Marco teórico y contextual	17
1.1 Microrredes fotovoltaicas	17
1.1.1 Contexto energético cubano	17
1.1.2 Microrredes FV: componentes, funcionamiento y desafíos	18
1.1.3 Análisis tecno-económico en el contexto de microrredes FV.....	19
1.2 Gemelos digitales	20
1.2.1 Definición, evolución y ventajas.....	20
1.2.2 Inteligencia artificial como parte del gemelo digital	21
1.3 Microrredes inteligentes.....	21
1.3.1 Integración de sistemas de información en la gestión energética.....	22
1.3.2 Estándares y normativas relevantes.....	23
1.3.3 Predicción de la generación fotovoltaica	24
1.3.4 Predicción de la demanda y del estado de almacenamiento	24
1.3.5 Detección de anomalías y mantenimiento predictivo en FV	25
1.3.6 Métricas y evaluación reproducible.....	25
1.3.7 Optimización operativa de la microrred	26
1.3.8 Gobernanza de IA, seguridad y operación fiable.....	26
1.3.9 Gobierno del dato y MLOps para el gemelo digital	27
1.4 Estado del arte de soluciones digitales para microrredes fotovoltaicas aisladas .	28
1.4.1 Plataformas comerciales integradas.....	28

1.5.2 Herramientas de simulación y diseño de microrredes	30
1.5.3 Plataformas IoT y de observabilidad open-source.....	31
1.5.4 Síntesis crítica y brechas en el contexto cubano	32
1.5 Análisis comparativo de stacks tecnológicos	33
1.5.1 Stack A – Plataforma IoT + observabilidad completamente open-source.....	33
1.5.2 Stack B – Solución basada en plataforma comercial tipo FusionSolar / SmartPVMS	35
1.6.3 Stack C – Stack híbrido seleccionado para el gemelo digital web	36
1.6.4 Justificación comparada del stack seleccionado	42
1.6 Conclusiones parciales del marco teórico.....	43
Capítulo 2. Diseño y desarrollo del gemelo digital web	45
2.1 Descripción general del sistema	45
2.2.1 Módulos principales del gemelo digital web.....	45
2.2.2 Datos y variables manejadas por el sistema	47
2.2.3 Fundamentos de los modelos de IA seleccionados.....	48
2.2.4 Modelos de inteligencia artificial incorporados.....	50
2.2.5 Visualización y analítica en la plataforma web.....	51
2.2.6 Funcionalidades principales del sistema	54
2.3 Requisitos del sistema, problemas frecuentes y atributos de calidad	56
2.3.1 Requisitos funcionales	56
2.3.2 Requisitos no funcionales	58
2.3.3 Problemas frecuentes y riesgos a mitigar	59
2.3.4 Atributos de calidad objetivos del diseño	60
2.4 Diagrama de casos de uso del sistema	62
2.4.1 Actores principales	63

2.4.2 Casos de uso y relaciones entre actores	¡Error! Marcador no definido.
2.4.3 Relación con requisitos y vistas arquitectónicas	¡Error! Marcador no definido.
2.5 Arquitectura candidata del sistema	63
2.5.1 Criterios de selección arquitectónica	70
2.5.2 Comparación de alternativas	¡Error! Marcador no definido.
2.5.3 Arquitectura candidata seleccionada	70
2.5.4 Relación con atributos de calidad y evolución futura	¡Error! Marcador no definido.
2.6 Estilos y patrones arquitectónicos.....	72
2.6.1 Estilo Llamada y Retorno. Patrones Cliente–Servidor y N-Capas	72
2.6.2 Estilo Centrado en Datos. Patrón Repositorio	76
2.6.3 Estilo de Flujo de Datos. Patrón Tuberías y Filtros	77
2.7 Principios y patrones de diseño	80
2.7.1 Principios generales de diseño	80
2.7.2 Principios SOLID en el gemelo digital.....	81
2.7.3 Patrones GRASP y asignación de responsabilidades	¡Error! Marcador no definido.
2.7.4 Patrones de diseño GoF aplicados.....	¡Error! Marcador no definido.
2.8 Reutilización y administración de la configuración.....	82
2.8.1 Estrategia de reutilización.....	82
2.8.2 Administración de la configuración	84
2.9 Conclusiones parciales del capítulo 2	86
Capítulo 3. Resultados, validación y análisis de modelos	87
3.1 Validación del modelo de clasificación y estimación de suciedad en paneles solares	88
3.1.1 Ejemplos de predicciones del modelo	88

3.1.2 Curva ROC y área bajo la curva (AUC)	89
3.1.3 Evolución de métricas durante el entrenamiento	90
3.1.4 Interpretación general de los resultados	91
3.2 Validación del modelo de predicción de generación solar con datos climáticos ..	92
3.2.1 Comparación de modelos mediante métricas de error y ajuste	92
3.2.2 Evaluación del modelo seleccionado: Random Forest	94
3.2.3 Relación entre variables climáticas y generación solar	95
3.2.4 Conclusión de la validación de generación	96
3.3 Validación del modelo de predicción de consumo energético universitario	97
3.3.1 Análisis de predicción vs. valores reales	97
3.3.2 Comparación entre modelos: R^2 , MAE y tiempo de entrenamiento	99
3.3.3 Predicción horaria de consumo	100
3.3.4 Conclusión general sobre el modelo de consumo	102
3.4 Conclusiones generales del capítulo 3.....	102
CONCLUSIONES GENERALES.....	105
RECOMENDACIONES	107
Referencias Bibliográficas.....	110
Tablas:	115

Introducción

La provisión eléctrica sostenible en territorios aislados y sistemas insulares constituye uno de los retos más exigentes de la transición energética. Este tipo de comunidades suele enfrentar altos costos de generación, una elevada vulnerabilidad ante fenómenos climáticos y una fuerte dependencia de combustibles importados. En muchas islas, producir electricidad puede costar hasta diez veces más que en regiones continentales comparables, lo que afecta de forma directa la asequibilidad y la seguridad energética, y limita el desarrollo local al restringir actividades productivas que dependen de un suministro confiable [1].

Esta situación es aún más crítica en localidades no interconectadas, donde los grupos electrógenos diésel continúan siendo la principal fuente de suministro, pese a su elevado costo por kWh y a la fragilidad logística del transporte de combustible. Estos sistemas dependen de cadenas de suministro vulnerables a interrupciones climáticas o marítimas, lo que incrementa los riesgos operativos y reduce la resiliencia comunitaria [2]. Por ello, mejorar la estabilidad energética de estos territorios no es solo una meta ambiental, sino también una condición habilitante para mejorar la calidad de vida y reducir la dependencia de combustibles importados.

En este contexto, las microrredes fotovoltaicas (FV) con almacenamiento han emergido como una opción técnica y económicamente viable para reemplazar o complementar la generación convencional. Estas soluciones permiten reducir el costo nivelado de energía (LCOE), aumentar la resiliencia frente a eventos extremos y disminuir las emisiones asociadas al uso de diésel. La evidencia internacional respalda esta tendencia: en 2024, el 91 % de la nueva capacidad renovable a escala de servicios públicos presentó un LCOE inferior al del combustible fósil más económico, lo que confirma la competitividad global de estas tecnologías [3]. Además, casos como Vieques y Culebra (Puerto Rico) muestran que la integración de FV y almacenamiento con control avanzado puede traducirse en beneficios económicos anuales, una disminución significativa del consumo

diésel y una mayor continuidad operativa incluso en escenarios de aislamiento prolongado [4].

Paralelamente al despliegue físico de activos energéticos, la digitalización se ha convertido en un habilitador fundamental para planificar, operar y mantener microrredes con mayor eficiencia. En este marco, el gemelo digital (Digital Twin, DT) se define como una representación virtual dinámica del sistema físico que se mantiene sincronizada con él mediante el intercambio continuo de datos. Su función es monitorear, diagnosticar, predecir el comportamiento del sistema y asistir en la toma de decisiones, permitiendo operar la microrred con información más precisa y actualizada. Este enfoque se ha consolidado como un paradigma ciber-físico-social en el sector energético, especialmente cuando incorpora arquitecturas por capas, tecnologías IoT/edge-cloud, modelos de datos interoperables y capacidades analíticas avanzadas para cerrar el ciclo percepción–decisión–actuación casi en tiempo real [5], [6].




Figura 1: Representación visual de Gemelo Digital

Antes de abordar su aplicación en energía, es importante precisar que la inteligencia artificial (IA) es un campo de la informática que desarrolla sistemas capaces de ejecutar tareas asociadas al razonamiento humano, como el reconocimiento de patrones, la predicción o la optimización. Dentro de la IA, el aprendizaje automático (Machine Learning, ML) permite construir modelos basados en datos históricos u operativos que mejoran su desempeño a medida que procesan nueva información. La combinación de IA y ML con gemelos digitales ha cobrado especial relevancia en los últimos años, al

potenciar su capacidad de análisis y predicción. Gracias a estas técnicas, los DT pueden mejorar la estimación del estado de los activos, anticipar fallas, optimizar la operación y reducir incertidumbres operativas en tiempo real, lo que incrementa el valor de la infraestructura física asociada. En aplicaciones fotovoltaicas, los DT se han consolidado especialmente en tres áreas: el modelado del rendimiento a nivel de planta, el mantenimiento predictivo mediante análisis de condición y la gestión energética con soporte de IA para la optimización operativa [7]. La literatura reciente demuestra que los marcos de predicción basados en datos permiten reducir la variabilidad de la generación, mientras que la detección temprana de anomalías mediante tecnología de sensores, IoT y aprendizaje profundo disminuye las paradas no planificadas y amplía la vida útil de los equipos, lo que obliga a considerar también medidas de ciberseguridad asociadas al flujo de datos energéticos [8], [9].

La integración de estos elementos requiere un controlador de microrred que cumpla lineamientos técnicos establecidos en normativas sectoriales, como IEEE 2030.7, para habilitar modos de isla intencional, reconfiguración segura y coordinación de recursos energéticos distribuidos (DER). El uso de controladores avanzados no solo mejora la estabilidad operativa, sino que facilita la integración de renovables variables dentro de un esquema seguro de protección y automatización [10]. Asimismo, una gestión basada en indicadores clave de desempeño (KPI) permite evaluar la calidad técnica, económica y de servicio de la microrred, apoyándose en metodologías recientes que estandarizan métricas, prácticas de monitoreo y recomendaciones aplicables en diferentes contextos geográficos y operativos [11].

En Cuba, el suministro eléctrico enfrenta desafíos estructurales asociados al envejecimiento del parque tecnológico, la limitada disponibilidad de combustible y la vulnerabilidad del sistema ante eventos climáticos severos. Esta combinación ha impulsado la búsqueda de alternativas más resilientes, sostenibles y de menor costo operativo, tanto a escala nacional como local. En territorios aislados como comunidades rurales o instalaciones descentralizadas estas limitaciones se intensifican, ya que el acceso al sistema electro energético nacional es limitado o inexistente. En dichos casos, predominan soluciones basadas en grupos electrógenos diésel, caracterizados por altos

costos por kWh, dependencia logística y baja eficiencia, replicando el patrón observado en múltiples sistemas insulares internacionales descritos por la literatura [1], [2].

La CUJAE no está ajena a esta realidad, pues en el marco de sus líneas investigativas sobre energías renovables y microrredes distribuidas, se han desarrollado laboratorios, prototipos e instalaciones experimentales que requieren un funcionamiento estable, seguro y eficiente. La microrred fotovoltaica aislada objeto de estudio forma parte de este ecosistema de investigación, y su correcta operación depende de una gestión energética que permita maximizar la generación renovable, reducir la incertidumbre operativa y anticipar fallos en sus componentes. Sin embargo, estas instalaciones carecen de mecanismos avanzados de monitoreo continuo, diagnóstico en tiempo real y soporte predictivo para las tareas de mantenimiento, lo que limita su desempeño académico, investigativo y tecnológico.

Este escenario configura **la situación problemática central**:

La necesidad de disponer de mecanismos modernos de control, supervisión, eficiencia operativa y confiabilidad del mantenimiento en microrredes fotovoltaicas aisladas del contexto cubano, especialmente en entornos universitarios como la CUJAE, donde estos sistemas son esenciales tanto para la investigación como para la docencia y la validación tecnológica. De esta **situación problemática** emerge el **problema científico**, que se formula:

¿Cómo garantizar la eficiencia operativa y la confiabilidad del mantenimiento en una microrred fotovoltaica aislada, mediante un sistema digital capaz de monitorear, predecir y apoyar la toma de decisiones en tiempo real?

A partir de este **problema**, se establece el siguiente **objetivo general**:

Desarrollar un gemelo digital web que integre técnicas de inteligencia artificial para asegurar la eficiencia operativa y la confiabilidad del mantenimiento de una microrred fotovoltaica aislada.

Este objetivo general se concreta en **tres objetivos específicos**, cada uno vinculado a uno de los capítulos principales del trabajo:

Objetivo específico 1: Fundamentar teóricamente la propuesta de un gemelo digital web con técnicas de inteligencia artificial para la gestión energética y el mantenimiento predictivo de microrredes fotovoltaicas aisladas en el contexto cubano y de la CUJAE.

Tareas asociadas:

a. Analizar el contexto energético cubano y el papel de las microrredes fotovoltaicas aisladas, con énfasis en las necesidades de eficiencia operativa y confiabilidad de mantenimiento en entornos académicos como la CUJAE.

Responsables: Ambos.

b. Estudiar los conceptos, características y arquitecturas de gemelos digitales aplicados a sistemas energéticos, identificando buenas prácticas de integración de datos, modelos y servicios web.

Responsables: Ambos.

c. Revisar la literatura sobre técnicas de inteligencia artificial y aprendizaje automático aplicadas al pronóstico de generación y consumo, así como a la detección de anomalías y mantenimiento predictivo en plantas solares.

Responsables: Ambos.

d. Caracterizar la microrred fotovoltaica aislada de referencia (topología, componentes, flujos energéticos y variables relevantes), definiendo los requisitos de información y de monitoreo que debe cubrir el gemelo digital.

Responsables: Ambos.

e. Analizar la arquitectura de referencia del gemelo digital fotovoltaico existente, identificando las adaptaciones necesarias para ajustarla al contexto de la microrred aislada de la CUJAE.

Responsables: Fabián (backend y servicios) y Rubén (frontend y experiencia de usuario).

Objetivo específico 2: Diseñar y desarrollar el gemelo digital web para la microrred fotovoltaica aislada, definiendo su arquitectura, modelo de datos, servicios de inteligencia artificial e interfaces de visualización y análisis en tiempo real.

Tareas asociadas:

a. Definir los requisitos funcionales y no funcionales del gemelo digital web, incluyendo casos de uso de gestión energética, mantenimiento predictivo, visualización de indicadores y perfiles de usuario.

Responsables: Ambos.

b. Diseñar la arquitectura de software del gemelo digital, detallando la separación entre backend (APIs, servicios de ML, integración con fuentes de datos) y frontend (dashboard web, componentes de visualización, flujo de navegación).

Responsables: Fabián (vista backend) y Rubén (vista frontend).

c. Diseñar el modelo de datos de la microrred y su representación en la base de datos, abarcando inventario de paneles, baterías, apagones programados, telemetría histórica y configuraciones del sistema.

Responsable principal: Fabián.

d. Implementar el backend del gemelo digital, integrando los servicios de telemetría, predicción de generación y consumo, simulación de autonomía de baterías y gestión de activos.

Responsable principal: Fabián.

e. Entrenar, ajustar y serializar los modelos de inteligencia artificial para pronóstico de generación y consumo, así como para la detección de patrones anómalos, documentando datasets, métricas de desempeño y proceso de actualización de modelos.

Responsable principal: Fabián.

f. Diseñar e implementar la interfaz web del gemelo digital, creando dashboards que muestren en tiempo (casi) real la producción, el consumo, el estado de las baterías, el clima, las predicciones y las alertas operativas.

Responsable principal: Rubén.

g. Integrar el frontend con el backend, garantizando el intercambio eficiente de datos y una experiencia de usuario fluida tanto para operadores técnicos como para usuarios

académicos.

Responsable principal: Rubén.

h. Documentar el flujo extremo a extremo del sistema (desde la captura o simulación de datos hasta la visualización y las recomendaciones), incluyendo diagramas de arquitectura, secuencia y despliegue.

Responsables: Ambos.

Objetivo específico 3: Validar el gemelo digital web desarrollado mediante pruebas funcionales, métricas de precisión de los modelos de inteligencia artificial y evaluación de su utilidad para la gestión y el mantenimiento de la microrred fotovoltaica aislada.

Tareas asociadas:

a. Diseñar y ejecutar casos de prueba funcional sobre el backend (servicios de predicción, consultas, manejo de errores) y sobre el frontend (navegación, actualización de datos, visualización de indicadores), verificando el cumplimiento de los requisitos definidos.

Responsables: Ambos (Fabián enfocado en backend, Rubén en frontend).

b. Evaluar el desempeño de los modelos de IA utilizados para la predicción de generación y consumo, contrastando los resultados con los objetivos de precisión establecidos para la microrred.

Responsable principal: Fabián.

c. Analizar la capacidad del gemelo digital para apoyar el mantenimiento predictivo, valorando la detección temprana de condiciones anómalas, la reducción potencial de paradas no planificadas y la mejora de la confiabilidad del sistema.

Responsables: Ambos.

d. Aplicar técnicas de evaluación de usabilidad y experiencia de usuario sobre la interfaz web, midiendo claridad, organización de la información, facilidad de interpretación de gráficos y carga cognitiva para el operador.

Responsable principal: Rubén.

e. Valorar, a nivel global, la contribución del gemelo digital web a la eficiencia operativa y a la confiabilidad del mantenimiento de la microrred fotovoltaica aislada, identificando limitaciones y proponiendo mejoras para futuras iteraciones y despliegues en otros escenarios de la CUJAE.

Responsables: Ambos.

El presente trabajo de tesis se estructura en tres capítulos:

Capítulo 1. Marco Teórico y Estudio de Viabilidad: Se contextualiza el desafío energético en comunidades aisladas y se analiza la dependencia de grupos electrógenos, junto con sus altos costos y limitaciones operativas. Se introduce el concepto de gemelo digital como herramienta para la gestión inteligente de microrredes FV y se describen los componentes de estas instalaciones. Se aborda el rol de la inteligencia artificial en la predicción de generación y en la detección de anomalías. Finalmente, se revisa el estado del arte, identificando limitaciones específicas para el contexto cubano y justificando la necesidad de una solución propia, adaptable y de bajo costo.

Capítulo 2. Diseño, Arquitectura y Desarrollo del Gemelo Digital: Se presenta la arquitectura del gemelo digital aplicado a la microrred fotovoltaica aislada. La plataforma web se organiza en cuatro módulos principales: captura de datos mediante tecnología de sensores, backend, base de datos e interfaz de usuario. Se explica la integración mediante APIs y el flujo continuo de datos en tiempo real. Se detalla el módulo de predicción basado en IA, sus datos de entrada, las métricas de validación y su integración con el backend. Asimismo, se justifica la selección del stack tecnológico priorizando herramientas de código abierto.

Capítulo 3. Resultados, Validación y Análisis Final: Se describe el prototipo funcional, recorriendo las vistas principales del sistema y sus capacidades de monitoreo, predicción y visualización. Se evalúa el rendimiento de la aplicación, la precisión del modelo predictivo y se discuten las limitaciones encontradas. Además, se analiza la escalabilidad del diseño para futuras implementaciones en entornos más complejos como las instalaciones de la CUJAE.

Conclusiones y Recomendaciones. Se sintetizan los resultados más relevantes, se discuten las contribuciones del trabajo y se plantean recomendaciones para investigaciones futuras. Se reflexiona sobre el impacto potencial de la plataforma y se identifican líneas de desarrollo que permitan avanzar hacia una solución más robusta y ampliamente aplicable.

Capítulo 1. Marco teórico y contextual

La transición hacia sistemas energéticos más resilientes y sostenibles ha pasado de ser un objetivo estratégico a una necesidad operativa, especialmente en territorios aislados, sistemas insulares y entornos donde la continuidad del servicio resulta crítica [1], [2]. En este escenario, las microrredes fotovoltaicas (FV) se consolidan como soluciones viables para reducir la dependencia del diésel, contener los costos y aumentar la resiliencia frente a eventos extremos. Paralelamente, la digitalización, la inteligencia artificial (IA) y los modelos híbridos físico–datos han abierto oportunidades para monitorear, analizar y optimizar la operación de estos sistemas en tiempo casi real [3], [6], [7].

Este capítulo desarrolla el marco teórico y contextual de la investigación, primero se analiza el papel de las microrredes fotovoltaicas y su pertinencia en el contexto energético cubano; luego se presentan los fundamentos conceptuales de los gemelos digitales y de la IA aplicada a sistemas energéticos; y, finalmente, se aborda la noción de microrredes inteligentes, donde convergen infraestructura física, algoritmos de predicción, optimización y prácticas de gobierno del dato para así llegar al análisis de soluciones de sistemas para microrredes aisladas y la comparación de las tecnologías aplicadas a estas.

1.1 Microrredes fotovoltaicas

Las microrredes son conjuntos de cargas y recursos energéticos distribuidos dentro de límites eléctricos definidos que operan como una entidad controlable. Pueden funcionar conectadas a la red o en modo isla, según las condiciones del sistema y las estrategias de operación [12], [13]. En su configuración fotovoltaica, integran generación solar, almacenamiento, posibles fuentes de respaldo y un sistema de control que coordina el flujo de energía y las transiciones entre modos de operación.

1.1.1 Contexto energético cubano

El sistema eléctrico cubano ha enfrentado, en los últimos años, contingencias asociadas al envejecimiento del parque generador, la limitada disponibilidad de combustibles fósiles y la exposición a fenómenos meteorológicos extremos. Estas condiciones han derivado en apagones recurrentes y en un uso intensivo de grupos electrógenos como respaldo,

incluidos polos turísticos y cayos, donde la operación con diésel encarece el kWh y aumenta la huella ambiental [14].

Frente a este panorama, el país ha comenzado a intensificar la incorporación de fuentes renovables y sistemas de almacenamiento. En 2025, el Ministerio de Energía y Minas informó avances en más de 50 parques solares fotovoltaicos apoyados por cooperación internacional, como parte de una estrategia para elevar la participación de las renovables hacia 2030 [15]. Este esfuerzo se alinea con la tendencia global identificada por la IEA y la IRENA, que muestra cómo las energías renovables, en particular la FV y la eólica, se han convertido en la opción de menor costo para nueva capacidad en la mayoría de los mercados [1], [3].

En contextos aislados, estas señales de política energética son especialmente relevantes. La posibilidad de desplegar microrredes FV con almacenamiento ofrece una vía práctica para reducir la dependencia del diésel, mitigar la volatilidad de precios y aumentar la resiliencia de comunidades y entornos de investigación, como los laboratorios de la CUJAE, donde la estabilidad del suministro influye directamente en la actividad académica y experimental [2], [14].

1.1.2 Microrredes FV: componentes, funcionamiento y desafíos

Una microrred fotovoltaica típica incluye los siguientes elementos [12], [13]:

- Generación solar: arreglos de módulos FV e inversores que convierten la energía solar en energía eléctrica utilizable.
- Almacenamiento de energía: bancos de baterías que permiten suavizar la variabilidad de la generación, aumentar la autonomía y respaldar cargas críticas.
- Generación de apoyo: grupos electrógenos u otras fuentes híbridas que actúan como respaldo en situaciones de baja irradiancia o alta demanda.
- Controlador de microrred (EMS/SCADA): sistema encargado de equilibrar generación y consumo, gestionar las transiciones red–isla y aplicar estrategias de despacho y protección.

Entre los principales beneficios de las microrredes FV se encuentran la mejora en la continuidad del servicio durante contingencias, la reducción de costos de operación mediante la optimización del uso de recursos, la disminución de emisiones y la menor dependencia de combustibles importados [12], [13].

No obstante, estos sistemas enfrentan desafíos técnicos significativos. La variabilidad de la generación solar exige modelos de predicción confiables para apoyar el despacho y la gestión del almacenamiento. La coordinación entre múltiples recursos y modos de operación introduce complejidades de protección, ciberseguridad y estabilidad que requieren estrategias de control avanzadas. En contextos reales, como el de Cayo Coco, se han evaluado algoritmos de optimización para la operación de microrredes híbridas basadas en generación convencional y renovable, evidenciando el potencial de mejorar la eficiencia mediante técnicas de gestión más sofisticadas [14].

1.1.3 Análisis tecno-económico en el contexto de microrredes FV

La viabilidad de una microrred fotovoltaica con almacenamiento se evalúa habitualmente a través de indicadores tecno-económicos como el costo nivelado de la energía (LCOE), la tasa interna de retorno (TIR) y el período de recuperación (payback). El LCOE se define como la razón entre el valor presente de los costos totales del sistema incluyendo inversión inicial (CAPEX), operación y mantenimiento (OPEX), reemplazos y, cuando aplica, combustible y el valor presente de la energía generada a lo largo de la vida útil [2], [3].

A escala global, la IRENA ha documentado reducciones sostenidas del LCOE de la energía solar fotovoltaica, tanto en plantas a gran escala como en sistemas distribuidos. En 2024, el 91 % de la nueva capacidad renovable comisionada resultó más económica que la alternativa fósil más barata disponible, lo que confirma el cambio estructural de competitividad a favor de las renovables [3]. En territorios aislados donde el costo logístico del diésel es elevado, diversos estudios muestran que el LCOE de configuraciones híbridas FV-batería puede situarse muy por debajo del costo marginal del diésel, aun considerando inversiones iniciales importantes y necesidades de reemplazo [2].

Estas evidencias refuerzan el interés en el despliegue de microrredes FV como solución para comunidades remotas, sistemas insulares y entornos de investigación. Además, abren la puerta a enfoques que combinan criterios económicos con métricas de resiliencia, como la capacidad de mantener cargas críticas durante eventos extremos, lo que ha sido explorado en evaluaciones tecno-económicas de microrredes para islas interconectadas [4].

1.2 Gemelos digitales

Los gemelos digitales han adquirido un papel destacado en la gestión de sistemas complejos, al combinar datos, modelos y capacidades de análisis para mejorar la operación, el mantenimiento y la planificación. En el ámbito energético, se consideran una pieza clave para avanzar hacia microrredes inteligentes capaces de medir, predecir y actuar de forma coordinada [5], [6].

1.2.1 Definición, evolución y ventajas

Un gemelo digital puede definirse como una representación virtual dinámica de un sistema físico que se mantiene sincronizada con él mediante el intercambio continuo de datos. Esta representación integra información estructural, operativa e histórica, así como modelos de simulación, con el fin de apoyar actividades de monitoreo, diagnóstico, pronóstico y optimización a lo largo del ciclo de vida del sistema [5], [6], [7].

Sus raíces conceptuales se remontan a los trabajos de Grieves en el ámbito del Product Lifecycle Management, donde se planteó la idea de una “fábrica virtual” que replica el comportamiento de la planta real, y a desarrollos de la NASA orientados a modelos “vivos” para la supervisión de sistemas aeroespaciales [16], [17]. A partir de estos antecedentes, el concepto se ha generalizado a dominios como manufactura, salud, ciudades inteligentes y sistemas energéticos.

En el contexto de la energía, los gemelos digitales habilitan cuatro capacidades principales [6], [7]:

1. Monitorización continua: integración de telemetría, datos ambientales y estados de operación.

2. Diagnóstico y detección temprana de anomalías: identificación de comportamientos inusuales y degradación de componentes.
3. Predicción del comportamiento: estimación de generación, demanda y estado de activos bajo diferentes escenarios.
4. Optimización operativa y soporte a la decisión: evaluación de políticas de control, estrategias de mantenimiento y escenarios what-if antes de aplicarlos en el sistema real.

Estas capacidades hacen de los gemelos digitales una herramienta especialmente atractiva para microrredes FV aisladas, donde las condiciones operativas son exigentes y cada decisión sobre generación, almacenamiento y mantenimiento tiene impactos directos en costos y confiabilidad.

1.2.2 Rol de la inteligencia artificial en el gemelo digital

La inteligencia artificial aporta al gemelo digital la capacidad de aprender de los datos y adaptar su comportamiento a cambios en las condiciones de operación. Dentro de la IA, las técnicas de aprendizaje automático (Machine Learning, ML) permiten construir modelos que capturan relaciones complejas entre variables, mejoran su desempeño a medida que reciben nueva información y generan pronósticos o clasificaciones útiles para la toma de decisiones [6], [8].

En el dominio fotovoltaico, las revisiones recientes enfatizan que un sistema de predicción eficaz no se limita a elegir un modelo, sino que requiere una tubería completa de datos y ML: adquisición y depuración de datos, selección de variables relevantes, entrenamiento y validación, cuantificación de la incertidumbre y actualización periódica conforme se dispone de nuevos registros operativos [8], [18]. Los enfoques híbridos que combinan conocimiento físico, por ejemplo, modelos eléctricos y térmicos de los módulos con técnicas de ML han mostrado ventajas en términos de generalización y robustez frente a condiciones cambiantes [18].

Cuando estas capacidades se integran dentro de un gemelo digital, este deja de ser solo una representación pasiva y se convierte en un espacio de control asistido y parcialmente autónomo. El flujo continuo de datos desde la microrred hacia el gemelo permite evaluar en tiempo casi real el estado del sistema, anticipar desbalances de generación y demanda, detectar anomalías y proponer acciones correctivas. A partir de los resultados de los modelos de IA, es posible ajustar dinámicamente consignas de operación, estrategias de uso del almacenamiento o prioridades de carga, cerrando el ciclo medir–analizar–actuar de forma iterativa.

De este modo, la IA no solo incrementa la capacidad predictiva del gemelo digital, sino que habilita un mecanismo de apoyo a la decisión que puede integrarse con el controlador de la microrred, permitiendo que la operación evolucione desde esquemas puramente manuales hacia modos de supervisión y control más automatizados y adaptativos.

1.3 Microrredes inteligentes

Las microrredes inteligentes representan la evolución natural de las microrredes tradicionales al incorporar tecnologías de información, comunicaciones, gemelos digitales e inteligencia artificial. Su objetivo es aprovechar los datos generados por la infraestructura eléctrica para tomar decisiones más informadas, robustas y oportunas sobre la operación y el mantenimiento.

1.3.1 Integración de sistemas de información en la gestión energética

El sistema de gestión de energía (Energy Management System, EMS) constituye la columna vertebral de una microrred inteligente. Este sistema orquesta la medición, la comunicación, el control y el análisis, y suele apoyarse en una arquitectura de tipo IoT–borde–nube [6]:

- En la capa de borde (edge) se ubican sensores, medidores inteligentes y controladores locales, responsables de adquirir datos de alta frecuencia y ejecutar decisiones de control con baja latencia.

- En la capa de nube se concentran el almacenamiento histórico, los procesos de análisis intensivo, el entrenamiento de modelos de IA y la visualización agregada.
- Entre ambas capas se articula una infraestructura de comunicaciones y servicios intermedios (APIs, pasarelas de datos, mecanismos de seguridad) que garantizan la interoperabilidad y la integridad de la información.

Este acoplamiento es fundamental para desplegar gemelos digitales en microrredes, pues permite mantener una representación actualizada del sistema, ejecutar simulaciones, analizar escenarios what-if y desplegar modelos de predicción y detección de anomalías integrados al flujo operativo.

1.3.2 Estándares y normativas relevantes

La operación fiable y segura de microrredes e infraestructuras asociadas a gemelos digitales requiere alinearse con normas y guías técnicas reconocidas. Entre las más relevantes se encuentran:

- IEEE 1547: regula la interconexión de recursos energéticos distribuidos, definiendo requisitos de respuesta ante perturbaciones, capacidades de control y criterios de protección.
- IEEE 2030.7/2030.8: establecen requisitos funcionales y procedimientos de prueba para controladores de microrred, incluyendo modos de operación en isla intencional y coordinación de recursos energéticos distribuidos [10].
- IEC 62443 y NIST Cybersecurity Framework: proporcionan marcos para la gestión de riesgos de ciberseguridad en sistemas de control industrial, con pautas sobre segmentación de redes, gestión de identidades y respuesta ante incidentes.
- Guías y reportes de NREL sobre microrredes: describen buenas prácticas para diseño, monitoreo y evaluación de desempeño, incluyendo conjuntos de indicadores aplicables a microrredes en contextos diversos [11], [12], [13].

El cumplimiento de estas normas no solo mejora la seguridad y la interoperabilidad, sino que también facilita la comparación de resultados y la transferencia de soluciones entre proyectos y contextos diferentes.

1.3.3 Predicción de la generación fotovoltaica

La predicción de la potencia generada por un sistema FV es una pieza central en la gestión de microrredes, pues condiciona decisiones sobre el uso del almacenamiento, la operación de grupos de respaldo y la priorización de cargas. Para este fin se combinan mediciones locales como irradiancia, temperatura de módulo y condiciones ambientales con pronósticos meteorológicos y, cuando es posible, datos de observación satelital o cámaras de cielo [8].

Los enfoques dominantes pueden agruparse en tres categorías [8], [18], [19]:

- Modelos de aprendizaje automático (ML): árboles de decisión, modelos de boosting, redes neuronales recurrentes (LSTM) y otras variantes que aprenden relaciones entre variables de entrada y potencia generada.
- Modelos híbridos físico–datos: integran ecuaciones físicas (por ejemplo, curvas I–V o modelos térmicos) con capas de ML, mejorando la interpretabilidad y la robustez frente a condiciones nuevas [18].
- Modelos probabilísticos: producen distribuciones de probabilidad o cuantiles en lugar de valores puntuales, lo que permite cuantificar la incertidumbre e incorporar criterios de riesgo en la toma de decisiones [19].

La literatura reciente muestra que los modelos híbridos suelen superar a los puramente estadísticos en entornos cambiantes, mientras que los pronósticos probabilísticos aportan valor operativo al reducir los costos asociados a decisiones subóptimas de despacho respecto a esquemas deterministas [18], [19].

1.3.4 Predicción de la demanda y del estado de almacenamiento

Además de la generación, una microrred inteligente requiere pronósticos de demanda y del estado de carga (State of Charge, SoC) de las baterías. Estas predicciones se abordan con técnicas similares a las utilizadas en fotovoltaica, combinando modelos de

regresión, redes neuronales recurrentes (LSTM) y arquitecturas orientadas a series temporales [20]. Los horizontes de predicción varían según la aplicación: desde minutos u horas útiles para control y operación en tiempo casi real hasta horizontes diarios o semanales orientados a la planificación. Las experiencias documentadas indican que los enfoques basados en aprendizaje profundo suelen mejorar el desempeño frente a métodos clásicos, siempre que la tubería de datos esté bien diseñada y se gestionen adecuadamente fenómenos como el drift de concepto [20].

1.3.5 Detección de anomalías y mantenimiento predictivo en FV

La detección temprana de anomalías es esencial para reducir paradas no planificadas y preservar la vida útil de componentes en plantas FV y microrredes. Se han propuesto modelos que, a partir de telemetría SCADA y datos de sensores, identifican patrones asociados a fallos como puntos calientes, desajustes, degradación de inversores o errores de configuración [7], [9]. Revisiones recientes destacan el avance de técnicas de aprendizaje profundo para este propósito, así como la necesidad de integrar la ciberseguridad como requisito transversal al mantenimiento predictivo. La combinación de tecnología de sensores, IoT y modelos de IA permite detectar anomalías de forma temprana, pero también introduce nuevos vectores de ataque sobre la infraestructura de comunicaciones y sobre la integridad de los datos [9].

1.3.6 Métricas y evaluación reproducible

La evaluación de modelos de predicción y detección de anomalías debe ser imparcial, trazable y reproducible. Iniciativas como el Solar Forecast Arbiter han desarrollado marcos abiertos para comparar modelos de pronóstico solar utilizando métricas estandarizadas, como MAE, RMSE, “skill score” frente a modelos de referencia (persistencia o ensembles) y medidas específicas para pronósticos probabilísticos, como el Continuous Ranked Probability Score (CRPS) [21], [22]. En paralelo, la comunidad del PV Performance Modeling Collaborative (PVPMC) ha promovido buenas prácticas y conjuntos de datos abiertos para la modelación y validación de sistemas FV, reduciendo la incertidumbre asociada al modelado y facilitando la comparación entre estudios [21]. Estos esfuerzos son relevantes para gemelos digitales en microrredes, ya que permiten anclar el desempeño de sus componentes de pronóstico a estándares reconocidos.

1.3.7 Optimización operativa de la microrred

Una vez disponibles los pronósticos de generación, demanda y estado de activos, la microrred debe decidir cómo operar: cuándo cargar o descargar baterías, cuánto respaldo diésel utilizar, qué cargas priorizar y cómo gestionar posibles restricciones de red. Para ello se utilizan diferentes familias de métodos [4], [23]:

- Programación matemática (MILP, MIQP, optimización estocástica): adecuada para planificación y despacho en horizontes discretos, con el objetivo de minimizar costos y emisiones bajo restricciones de potencia, energía y SoC.
- Control predictivo basado en modelo (Model Predictive Control, MPC): emplea modelos dinámicos del sistema y resuelve problemas de optimización en un horizonte recedente, lo que permite ajustar decisiones en tiempo casi real e incorporar explícitamente limitaciones físicas.
- Aprendizaje por refuerzo profundo (Deep Reinforcement Learning, DRL): aprende políticas de control a través de la interacción con un entorno simulado, resultando prometedor para escenarios con alta dimensionalidad y fuerte incertidumbre, aunque requiere diseños cuidadosos de entrenamiento y validación antes de su despliegue en sistemas reales [23].

En estudios de microrredes insulares, se ha demostrado que la incorporación explícita de métricas de resiliencia y costos de interrupción en estos enfoques de optimización permite valorar mejor los beneficios de estrategias como la isla intencional, el uso de almacenamiento y la flexibilidad de cargas [4].

1.3.8 Gobernanza de IA, seguridad y operación fiable

El despliegue de IA en sistemas energéticos trae consigo retos relacionados con la aplicabilidad de los modelos, la gobernanza algorítmica y la seguridad de los datos. En el contexto de plantas solares y microrredes, los trabajos recientes subrayan la importancia de asegurar la integridad y la confidencialidad de la información utilizada por los modelos de mantenimiento predictivo y control, así como de garantizar trazas de auditoría que permitan reconstruir decisiones tomadas por los sistemas inteligentes [9], [20]. Un enfoque responsable incluye, control de acceso y cifrado en tránsito y en reposo;

registro de versiones de modelos y datos de entrenamiento; mecanismos de detección de comportamientos anómalos tanto en la infraestructura física como en los modelos de IA; procesos de validación periódica que permitan detectar degradación del desempeño o sesgos emergentes [9], [20]. Estas consideraciones son particularmente importantes cuando la IA forma parte de un gemelo digital que interactúa directamente con activos físicos de la microrred.

1.3.9 Gobierno del dato y MLOps para el gemelo digital

El desempeño sostenido de los modelos de pronóstico y detección de anomalías en un gemelo digital depende de un gobierno de datos sólido y de prácticas de MLOps bien definidas. Desde la perspectiva del gobierno del dato, resulta necesario contar con [20]:

- catálogos de datos y diccionarios de variables,
- políticas claras de calidad, retención y acceso,
- control de versiones de conjuntos de datos y trazabilidad de transformaciones (data lineage).

En cuanto a MLOps, se recomienda establecer [20]:

- separación de entornos (desarrollo, pruebas, producción),
- registros de modelos (model registry) con sus métricas de desempeño,
- monitoreo continuo de deriva de datos (data drift) y de concepto (concept drift),
- procedimientos de reentrenamiento y *rollback* ante degradación del rendimiento.

La reproducibilidad se refuerza mediante el control de versiones de código y datos, el empaquetado de dependencias y la definición de *pipelines* declarativos para las etapas de entrenamiento, evaluación y despliegue. Integrar estas prácticas en el diseño de un gemelo digital web para microrredes FV es un requisito para garantizar que las capacidades de IA mantengan su calidad y fiabilidad a lo largo del tiempo.

1.4 Estado del arte de soluciones digitales para microrredes fotovoltaicas aisladas

Este epígrafe analiza las principales soluciones digitales existentes para la monitorización, gestión energética y mantenimiento de instalaciones fotovoltaicas y microrredes, con énfasis en aquellas que incorporan conceptos de gemelo digital o funcionalidades cercanas. El objetivo no es solo describir productos, sino identificar patrones de arquitectura, funcionalidades y limitaciones que sirvan de referencia para el diseño del gemelo digital web propuesto.

1.4.1 Plataformas comerciales integradas

Huawei FusionSolar (App + SmartPVMS)

Huawei ofrece un ecosistema completo de gestión fotovoltaica formado por la aplicación móvil FusionSolar y el sistema web Smart PV Management System / SmartPVMS, orientado a instaladores y propietarios de plantas FV. La app permite la puesta en marcha guiada de plantas, la configuración de equipos y la monitorización en cualquier momento y lugar, integrando funciones de condicionamiento, ajuste de parámetros, actualización de firmware y operación y mantenimiento (O&M) móvil de las plantas fotovoltaicas [24].

SmartPVMS, por su parte, es un sistema de supervisión y O&M que muestra en forma centralizada el estado actual e histórico de múltiples plantas, con paneles (dashboards) donde se visualizan potencia instantánea, energía generada, indicadores de O&M y alarmas en tiempo real [25]. Incluye análisis estadístico de rendimiento por planta, informes descargables y diagnósticos automáticos (como análisis de tasa de dispersión de strings), orientados a reducir tiempos de inspección y focalizar el mantenimiento [25].

Aunque el acceso a FusionSolar y SmartPVMS está restringido a usuarios registrados (instaladores y propietarios con credenciales válidas), en esta investigación se estudió la plataforma a través de una fuente que ya dispone de acceso, lo que permitió analizar flujos de interacción, organización de vistas, tipo de KPI y manejo de alarmas. Sobre esa base, la aplicación propuesta se inspira en el diseño de listas de plantas, flujos de energía en tiempo real, paneles de rendimiento y gestión de alarmas de FusionSolar, pero adaptándolos a:

- el contexto cubano de microrredes aisladas y su uso de código abierto, con condiciones de conectividad intermitente;
- necesidades específicas de predicción (generación, demanda, estado de almacenamiento) a nivel de microrred, más allá del autoconsumo residencial;
- requerimientos académicos y de replicabilidad, que exigen una solución auto hospedable y basada en tecnologías abiertas.

Las funcionalidades se reinterpretan, por tanto, como patrones de diseño (estructura de dashboard, navegación por plantas, visualización de flujo de energía y alarmas) y no como una réplica funcional cerrada de la plataforma comercial [25].

ABB Ability™ Energy Manager

ABB Ability™ Energy Manager es una solución en la nube para monitorizar y optimizar el consumo energético y la huella de CO₂ en instalaciones industriales, comerciales y de servicios públicos. Proporciona indicadores en tiempo real, análisis comparativo entre sitios y herramientas para la toma de decisiones orientadas a eficiencia y sostenibilidad [26].

En el contexto del gemelo digital, ABB Ability funciona como una plataforma de gestión integral: conecta equipos físicos mediante hardware específico de ABB (medidores, gateways), centraliza datos y ofrece analítica avanzada. Su posición en el estado del arte evidencia la tendencia a soluciones “llave en mano” de fabricantes consolidados, pero también resalta sus limitaciones: costos de licencia elevados, dependencia de hardware propietario y menor flexibilidad para adaptaciones específicas, especialmente en entornos académicos o de baja disponibilidad de divisas.

Siemens Spectrum Power™ 5

Spectrum Power™ 5 es un sistema avanzado de gestión de redes para operadores de distribución, industrias y municipios, orientado a la supervisión y control de redes eléctricas de pequeña y mediana escala. Integra funciones SCADA, DMS y herramientas

de análisis que buscan maximizar eficiencia, fiabilidad y preparación para futuros escenarios de red [27].

Aunque está más enfocado a sistemas de distribución que a microrredes aisladas, su arquitectura y capacidades refuerzan tendencias clave: integración de datos operativos, analítica avanzada, soporte a decisiones en tiempo real y modularidad. Sin embargo, como en el caso de ABB, se trata de una solución comercial de alto costo, cuya adopción directa en el contexto cubano resulta poco realista para una microrred FV aislada de escala reducida.

El análisis de estas plataformas muestra un conjunto de requisitos funcionales que el gemelo digital propuesto debe considerar: vista unificada de la planta, representación explícita del flujo de energía, paneles de KPI configurables, alarmas en tiempo real, informes históricos y, en el caso de FusionSolar, elementos de predicción y gestión inteligente del almacenamiento orientados a maximizar ingresos y autoconsumo.

1.5.2 Herramientas de simulación y diseño de microrredes

En un nivel diferente, orientado al diseño y planificación más que a la operación diaria, se encuentran herramientas como GridLAB-D, HOMER y OpenDSS.

- **GridLAB-D** es un simulador de sistemas de distribución desarrollado para explorar tecnologías de red inteligente, permitiendo analizar el comportamiento eléctrico de la microrred en múltiples escenarios operativos y de penetración renovable [28].
- **HOMER** es el estándar de facto para el diseño y optimización tecno-económica de microrredes e híbridos, integrando modelos de recursos, componentes y costos para encontrar configuraciones de menor coste y mayor fiabilidad [29].
- **OpenDSS**, desarrollado por EPRI, es un simulador de sistemas de distribución que soporta un amplio abanico de análisis en estado estacionario y es utilizado extensamente en estudios de integración de generación distribuida y modernización de redes [30].

Estas herramientas inspiran el componente de simulación y análisis offline del gemelo digital web (p. ej., para escenarios what-if o para generar datos sintéticos de entrenamiento), pero no ofrecen, por sí mismas, una interfaz web integrada ni un flujo de trabajo de operación diaria con dashboards, alarmas y analítica en tiempo real.

1.5.3 Plataformas IoT y de observabilidad open-source

En un tercer grupo se sitúan plataformas open-source orientadas a IoT y observabilidad, fundamentales para construir gemelos digitales energéticos flexibles:

- **ThingsBoard** es una plataforma IoT de código abierto para gestión de dispositivos, recolección de datos, procesamiento y visualización, con soporte para protocolos estándar (MQTT, CoAP, HTTP) y despliegue tanto en la nube como on-premise [31].
- **Grafana** se ha consolidado como referencia para la visualización de series temporales, permitiendo construir dashboards web altamente configurables que muestran métricas a lo largo del tiempo (potencia, estado de baterías, alarmas, etc.) [32].
- **InfluxDB** es una base de datos de series temporales optimizada para manejar grandes volúmenes de datos con marca de tiempo en tiempo real, ampliamente utilizada como backend para métricas e IoT [33].
- **TensorFlow** proporciona un ecosistema abierto para el desarrollo, entrenamiento y despliegue de modelos de aprendizaje automático en múltiples entornos, por lo que suele emplearse como “cerebro predictivo” en soluciones de mantenimiento y pronóstico energéticos [34].

En conjunto, estas tecnologías ofrecen un patrón de arquitectura frecuente en gemelos digitales: capa de ingesta IoT + base de datos de series temporales + dashboards + motor de IA. Siendo precisamente esta combinación una de las opciones más robustas para un gemelo digital de microrredes.

1.5.4 Síntesis crítica y brechas en el contexto cubano

Del contraste entre plataformas comerciales (FusionSolar, ABB, Spectrum Power 5), herramientas de diseño (GridLAB-D, HOMER, OpenDSS) y stacks open-source (ThingsBoard, Grafana, InfluxDB, TensorFlow) se derivan varias conclusiones relevantes para el caso de estudio:

1. Todas las soluciones convergen en ciertos elementos: vista consolidada de la planta o microrred, monitorización en tiempo real, históricos y reportes, alarmas y, cada vez más, analítica predictiva y soporte a decisiones. FusionSolar, en particular, muestra una integración ejemplar de flujo de energía, gestión de dispositivos y visualización de beneficios ambientales que se toma como referencia directa para el diseño de la interfaz propuesta [24].
2. Las soluciones comerciales presentan barreras de acceso: licencias de costo elevado, necesidad de hardware propietario, dependencia de conectividad estable a servicios en la nube y restricciones de acceso para usuarios que no sean clientes directos. Estas condiciones dificultan su uso en un entorno de investigación universitaria y en microrredes aisladas de pequeña escala en Cuba.
3. Brechas específicas.
 - Falta de adaptación al contexto cubano (esquemas tarifarios, restricciones de combustible diésel, condiciones de conectividad, normativas locales).
 - Escasa posibilidad de experimentar con modelos de IA propios, reentrenar algoritmos y auditar su comportamiento.
 - Necesidad de control pleno sobre los datos operativos (gobierno del dato) para fines de investigación y validación.
4. Dirección de diseño para el gemelo digital web.
 - Se prioriza un stack open-source y auto hospedable, que reproduzca los patrones de UX y las funcionalidades clave observadas en FusionSolar y plataformas similares, pero con libertad para modificar y extender.

- Se adoptan los principios arquitectónicos identificados en las plataformas IoT (separación de ingesta, almacenamiento, visualización y analítica), reutilizando ideas de ThingsBoard, Grafana, InfluxDB y TensorFlow, pero con una implementación más ligera y alineada con las capacidades del entorno universitario.

1.5 Análisis comparativo de stacks tecnológicos

Sobre el estado del arte anterior se evalúan diferentes combinaciones tecnológicas susceptibles de soportar el gemelo digital web. A continuación, se presentan dos stacks alternativos, derivados de las soluciones analizadas, y posteriormente se resume el stack finalmente seleccionado y su justificación frente a las alternativas.

1.5.1 Stack A – Plataforma IoT + observabilidad completamente open-source

Este stack toma como base la combinación clásica ThingsBoard + InfluxDB + Grafana + TensorFlow.

Tecnología	Rol en la arquitectura	Justificación para el problema	Riesgos y mitigaciones
ThingsBoard	Backend IoT central para gestión de dispositivos, ingesta de telemetría y definición de reglas.	Proporciona un núcleo de gemelo digital listo para usar (gestión de dispositivos, colas de datos, reglas de negocio y dashboards básicos) que reduce el esfuerzo de construcción desde cero [31].	Complejidad de despliegue (múltiples servicios, base de datos adicional) y curva de aprendizaje elevada. Mitigación: despliegue escalonado, uso inicial en modo “single-node” y automatización mediante contenedores.
InfluxDB	Base de datos de series temporales para	Optimizada para altas tasas de escritura y consultas sobre	Introduce otro motor de base de datos a administrar. Mitigación:

	mediciones de sensores, estados y predicciones.	millones de puntos de datos, ideal para registros de potencia, tensión y estado de baterías [33].	centralizar métricas energéticas en InfluxDB y mantener otros datos en una base documental o relacional ligera.
Grafana	Capa de visualización para dashboards en tiempo real e históricos.	Permite construir paneles similares a los observados en FusionSolar y ABB Ability con poco código, integrando datos de InfluxDB y otras fuentes [32].	Dependencia de un sistema externo para la visualización; posible solapamiento con componentes frontend propios. Mitigación: usar Grafana para vistas de operación y reservar el frontend propio para flujos de negocio específicos.
TensorFlow	Motor de IA para modelos de pronóstico y detección de anomalías.	Plataforma estándar para construir y desplegar modelos de mantenimiento predictivo y predicción de generación FV en producción [34].	Necesidad de gestionar ciclos de vida de modelos y recursos de cómputo. Mitigación: comenzar con modelos ligeros, usar entornos virtualizados y definir una estrategia básica de MLOps.

Tabla 1: Primer stack tecnológico

Valoración. Este stack ofrece una solución robusta y ampliamente utilizada en proyectos reales de gemelos digitales e IoT. Sin embargo, puede resultar excesivo para el alcance

de una microrred aislada en entorno universitario, tanto por complejidad de despliegue como por la necesidad de administrar varios componentes pesados.

1.5.2 Stack B – Solución basada en plataforma comercial tipo FusionSolar / SmartPVMS

Este segundo stack considera la posibilidad de apoyarse en una plataforma comercial existente, emulando una arquitectura similar a la de FusionSolar.

Tecnología	Rol en la arquitectura	Justificación para el problema	Riesgos y mitigaciones
FusionSolar App	Interfaz móvil de monitorización y O&M para plantas FV.	Ofrece una experiencia de usuario madura para seguimiento en tiempo real, alarmas y control básico de dispositivos, con soporte oficial del fabricante [24].	Acceso restringido a clientes con credenciales; poca capacidad de modificar flujos o añadir módulos de predicción específicos. Mitigación: solo viable como referencia de diseño, no como solución integrada en el proyecto.
SmartPVMS / Smart PV Management System	Portal web para supervisión centralizada de plantas, informes, diagnósticos y gestión de alarmas.	Brinda paneles avanzados, informes descargables, análisis de strings y diagnósticos automáticos, alineados con las necesidades de	Plataforma cerrada, no instalable on-premise en el contexto del proyecto, dependiente de servicios en la nube de Huawei y de hardware propietario. Mitigación: uso únicamente como

		O&M de plantas FV [25].	benchmark funcional y de UX.
Ecosistema de inversores, optimizadores y sensores Huawei	Capa física integrada con la plataforma digital.	Permite una integración vertical muy eficiente entre hardware y software, con diagnósticos avanzados (curvas I-V, análisis de variación, etc.) [25].	Costos elevados, dependencia del fabricante y baja probabilidad de implementación completa en una microrred experimental en Cuba. Mitigación: sustituir por componentes comerciales genéricos y gemelo digital propio.

Tabla 2: Segundo stack Tecnológico

Valoración. Aunque esta opción maximiza la madurez industrial, es incompatible con las restricciones de acceso, presupuesto y personalización del proyecto de microrred. Este stack explícitamente de FusionSolar y SmartPVMS se utilizará solo como referencia conceptual y de experiencia de usuario, no como base tecnológica directa.

1.6.3 Stack C – Stack híbrido seleccionado para el gemelo digital web

El stack finalmente seleccionado, se concibe como una síntesis ligera y abierta de los patrones observados en el estado del arte.

A nivel de componentes principales:

Tecnología	Rol en la arquitectura	Justificación específica para el proyecto	Riesgos y mitigaciones

Next.js (React)	Capa de presentación para dashboards y vistas de operación y administración del gemelo digital.	Framework full-stack de React orientado a producción, con fuerte soporte comunitario y capacidades modernas de enrutamiento y renderizado, adecuado para construir interfaces auto-hospedadas similares a las de plataformas comerciales. En este caso, los tableros administrativos priorizan interactividad, manejo de estados complejos en cliente y sesiones prolongadas, por lo que el modelo de componentes de React y su ecosistema de bibliotecas de visualización y	Complejidad en la gestión de estado y enrutamiento, así como riesgo de sobrecarga de estado en cliente. Mitigación: seguir patrones recomendados (App Router, contextos bien definidos), usar patrones de gestión de estado (Context/Redux/Zustand) y aplicar <i>code-splitting</i> para optimizar rendimiento.
--------------------	---	--	---

		formularios reducen la complejidad y el costo operativo [35].	
FastAPI (Python)	API principal y orquestación de lógica de negocio y modelos de IA.	Framework de alto rendimiento con tipado fuerte y documentación automática, ideal para integrar modelos de predicción y detección de anomalías en Python dentro del gemelo digital. Ofrece validación estricta de datos y soporte para concurrencia, lo que facilita la ingesta de datos meteorológicos y operativos en paralelo con los procesos de predicción [36].	Riesgo de endpoints monolíticos o excesivamente complejos. Mitigación: aplicar arquitectura por capas (controladores, servicios, repositorios), acompañar con pruebas automatizadas y dotar al sistema de observabilidad (métricas, <i>logging</i> estructurado y trazas).
GraphQL	Fachada de datos para consultas compuestas	Permite que las vistas del gemelo digital soliciten exactamente los datos que necesitan	Complejidad en la implementación de <i>resolvers</i> y en el control de costes de consultas. Mitigación: uso de <i>batching</i> y <i>caching</i> ,

	desde el frontend.	(por ejemplo, métricas de una planta, alarmas activas y predicciones) en una sola consulta, reduciendo sobrecargas e infra-obtención de datos. El esquema tipado facilita la evolución controlada del modelo de información y habilita, en el futuro, suscripciones para actualizaciones casi en tiempo real en dashboards complejos [37].	establecimiento de límites de profundidad y coste de las consultas, así como monitorización continua de patrones de uso.
MongoDB (documental + colecciones de series temporales)	Persistencia unificada de metadatos de la microrred y series temporales (medidas y predicciones).	Las colecciones de series temporales nativas permiten almacenar mediciones de sensores de forma eficiente sin introducir un motor adicional, manteniendo en la misma base de	Riesgo de consultas ineficientes si los esquemas y los índices no se diseñan adecuadamente. Mitigación: diseño cuidadoso de claves temporales y de particionado lógico (por planta/activo), creación de índices compuestos alineados con los patrones de consulta y, en caso

		datos tanto la configuración y metadatos (paneles, baterías, parámetros de la microrred) como las series temporales y predicciones. Se aprovechan, además, políticas de retención (TTL), compresión y <i>Change Streams</i> para notificaciones en vivo, evitando fragmentar el dato entre varios motores [38].	necesario, <i>sharding</i> por planta y rango temporal.
Motor de IA en Python (scikit-learn)	Entrenamiento y despliegue de modelos de predicción de generación, demanda y estado de activos.	scikit-learn proporciona un conjunto maduro de algoritmos clásicos de aprendizaje supervisado y no supervisado (regresión, clasificación, <i>clustering</i>), suficiente para los modelos de pronóstico y	Necesidad de gestionar versiones de modelos y su rendimiento en operación (deriva de datos, pérdida de precisión). Mitigación: definición de un flujo básico de MLOps (registro de modelos y parámetros, métricas de validación, reentrenamiento periódico con datos recientes) y uso de pruebas de regresión

		detección de anomalías previstos en el proyecto. Se integra de forma natural con el ecosistema científico de Python (NumPy, pandas, SciPy) y con FastAPI, permitiendo ciclos de experimentación rápidos y modelos relativamente ligeros de mantener y desplegar [39].	sobre los modelos antes de su despliegue.
Open-Meteo u otra API de radiación satelital	Fuente de datos meteorológicos e irradiancia para alimentar los modelos de predicción.	APIs abiertas de meteorología y radiación satelital proporcionan irradiancia global, directa y difusa, así como variables atmosféricas relevantes (temperatura, nubosidad, viento, precipitación), sin costo de licencia, lo que las hace adecuadas para	Dependencia de conectividad a Internet y posible variabilidad en la precisión regional de los datos. Mitigación: almacenamiento en caché local de las series descargadas, calibración por planta comparando con mediciones in situ cuando estén disponibles y validación cruzada de los modelos frente a diferentes periodos históricos.

		alimentar modelos de generación FV y realizar <i>backtesting</i> histórico [40].	
--	--	--	--

Tabla 3: Tercer stack tecnológico

1.6.4 Justificación comparada del stack seleccionado

A la luz de los tres stacks considerados, la elección del Stack C se justifica por los siguientes argumentos:

1. Equilibrio entre madurez y control.

- Frente al Stack B (FusionSolar/SmartPVMS), el Stack C evita la dependencia de plataformas cerradas, manteniendo control total sobre datos y lógica de negocio.
- Frente al Stack A (ThingsBoard + InfluxDB + Grafana + TensorFlow), logra una solución más ligera en número de componentes, sin renunciar a principios fundamentales de las arquitecturas IoT/gemelo digital.

2. Apropiación de patrones exitosos.

- Del ecosistema FusionSolar toma la idea de vista integral de planta, flujo de energía, alarmas y métricas económicas/ambientales, pero la implementa sobre un frontend propio en Next.js y dashboards diseñados.
- De las plataformas IoT y de observabilidad adopta la separación conceptual entre ingesta, almacenamiento de series temporales, visualización y analítica, pero sin incorporar la complejidad de desplegar ThingsBoard y Grafana, ya que el frontend cubre las necesidades de visualización y MongoDB asume la función de base temporal.

3. Adecuación al contexto cubano y al entorno universitario.

- Todas las tecnologías clave del Stack C son open-source y pueden ejecutarse on-premise, lo que reduce barreras de licencia y dependencia de conectividad externa.
- La arquitectura facilita que futuros equipos de investigación puedan modificar los modelos de IA, cambiar fuentes de datos o extender el gemelo digital a otras microrredes o contextos sin quedar atados a un proveedor.

4. Capacidad de integración con simulación y análisis offline.

- El backend en FastAPI y el motor de IA en Python facilitan integrar, en el futuro, módulos que consuman resultados de simulación provenientes de herramientas como GridLAB-D, HOMER u OpenDSS, cerrando así el ciclo diseño–simulación–operación dentro de un mismo gemelo digital.

El stack elegido reúne lo mejor de las soluciones existentes: reproduce funcionalidades clave de plataformas líderes (como FusionSolar o ABB Ability), incorpora patrones de arquitectura de las plataformas IoT y de observabilidad, y los adapta a un entorno off-grid y académico, maximizando flexibilidad, control y capacidad de experimentación con IA.

1.6 Conclusiones parciales del marco teórico

El marco teórico y contextual desarrollado permite sintetizar los elementos clave que sustentan la propuesta de un gemelo digital web para la gestión energética y el mantenimiento predictivo de una microrred fotovoltaica aislada. En primer lugar, el análisis del contexto energético y de la problemática actual en Cuba confirma que las microrredes FV con almacenamiento constituyen una alternativa técnicamente viable y económicamente competitiva frente a esquemas basados en grupos electrógenos diésel, al reducir el costo nivelado de la energía, mitigar la exposición a la volatilidad del combustible y elevar la resiliencia ante eventos extremos. En segundo término, la revisión de los fundamentos conceptuales muestra que el gemelo digital, entendido como representación virtual sincronizada del sistema físico, se configura como un habilitador central para cerrar el ciclo medir–anticipar–actuar en microrredes. La combinación de tecnología de sensores, comunicaciones IoT/edge–cloud, modelos híbridos físico–datos

e Inteligencia Artificial permite integrar capacidades de monitorización continua, diagnóstico temprano, pronóstico de generación, demanda y estado de activos, así como optimización operativa, siempre bajo el marco de estándares y normativas que garantizan interoperabilidad, seguridad y operación fiable.

El estudio de la literatura sobre pronóstico, detección de anomalías y optimización mediante IA evidencia que estos componentes constituyen el “núcleo inteligente” del gemelo digital propuesto. Los enfoques modernos de predicción fotovoltaica y de demanda, las técnicas de mantenimiento predictivo y los esquemas de optimización (programación matemática, MPC, DRL) se apoyan en prácticas de gobierno del dato y MLOps que resultan imprescindibles para sostener el desempeño del sistema en el tiempo y asegurar la trazabilidad de los modelos y de sus decisiones. El análisis crítico del estado del arte de soluciones comerciales, herramientas de simulación y plataformas open-source pone de manifiesto patrones arquitectónicos recurrentes, capa de ingesta IoT, bases de datos de series temporales, dashboards web y motor de IA, pero también brechas específicas para el contexto cubano, relacionadas con costos de licencia, dependencia de hardware propietario y restricciones de conectividad. De este contraste se deriva la pertinencia de una solución auto hospedable, basada en tecnologías abiertas y adaptada a las necesidades de investigación y operación de microrredes aisladas. En el Capítulo 2, se detallará el diseño, la arquitectura y el desarrollo del gemelo digital web que materializa los principios y requisitos identificados en el presente capítulo.

Capítulo 2. Diseño y desarrollo del gemelo digital web

El capítulo anterior presentó los fundamentos conceptuales de las microrredes fotovoltaicas, los gemelos digitales y el papel de la inteligencia artificial en la predicción y el mantenimiento, con énfasis en contextos insulares y campus universitarios como la CUJAE. Sobre esa base, este capítulo describe la solución propuesta: un gemelo digital web orientado a una microrred fotovoltaica aislada, concebido como herramienta de apoyo a la operación, el análisis y la toma de decisiones en entornos con restricciones de infraestructura y de recursos humanos especializados.

La solución se organiza en módulos que separan la adquisición de datos, la analítica basada en IA, la simulación energética y la visualización en una interfaz web. Modularizar facilita la evolución del sistema y la incorporación futura de nuevas fuentes de datos o modelos, manteniendo al mismo tiempo una experiencia de usuario coherente. En las secciones siguientes se describen los módulos, los tipos de datos y variables empleados, los modelos de IA integrados y las funcionalidades principales del sistema; a continuación, se formulan los requisitos funcionales y no funcionales, los problemas frecuentes a mitigar y los atributos de calidad que guían el diseño. Estos elementos establecen la base conceptual sobre la cual se desarrolla, en secciones posteriores, el diseño de software, la arquitectura candidata y, los estilos y patrones utilizados para integrar los módulos físicos y digitales.

2.1 Descripción general del sistema

El sistema propuesto es un gemelo digital web que representa, de forma virtual y dinámica, el comportamiento de una microrred fotovoltaica aislada. Combina datos de telemetría (reales o simulados), modelos de predicción basados en inteligencia artificial, lógica de negocio y una interfaz web interactiva para asistir a operadores y responsables técnicos en la toma de decisiones. El gemelo digital no se limita a visualizar el estado actual de la microrred, sino que integra capacidades de pronóstico, análisis de escenarios y soporte al mantenimiento.

2.2.1 Módulos principales del gemelo digital web

El gemelo digital web se estructura en cuatro módulos principales interconectados entre sí:

1. Módulo de adquisición y gestión de datos operativos: Encargado de integrar y almacenar la información necesaria para representar el estado de la microrred. Incluye telemetría de generación fotovoltaica, consumo, estado de carga de baterías y flujos de energía. Gestiona datos meteorológicos históricos y de pronóstico (temperatura, humedad relativa, velocidad del viento, nubosidad, irradiancia global, entre otros). Registra eventos relevantes para la continuidad del servicio.
2. Módulo de analítica y modelos de inteligencia artificial: Agrupa los modelos de predicción de generación y consumo, los servicios de estimación de autonomía de baterías y el modelo de clasificación de imágenes para evaluar la limpieza de paneles. Este módulo opera sobre los datos gestionados por el módulo anterior y expone sus resultados a los demás componentes del sistema.
3. Módulo de simulación y servicios de dominio: Integra datos, pronósticos y configuración del sistema para generar líneas de tiempo de producción y demanda esperada, estimaciones de autonomía, alertas operativas y recomendaciones. En este módulo se encapsulan reglas de negocio específicas de la microrred, como umbrales de estado de carga, criterios de priorización de cargas y manejo de apagones programados.
4. Módulo de interfaz web y experiencia de usuario: Proporciona un tablero interactivo donde se visualizan los indicadores clave, las series temporales de producción y consumo, las condiciones meteorológicas, las predicciones de IA y el inventario de activos (paneles, baterías, apagones). Este módulo consume los servicios expuestos por el backend y traduce la complejidad del sistema en vistas comprensibles para operadores, docentes y estudiantes.

La separación en módulos favorece la mantenibilidad y la escalabilidad del sistema, al permitir que cada componente evolucione de forma relativamente independiente, de acuerdo con las recomendaciones de diseño modular para sistemas complejos y gemelos digitales energéticos [41].

2.2.2 Datos y variables manejadas por el sistema

El gemelo digital trabaja con tres grandes familias de datos: variables meteorológicas, variables eléctricas y variables temporales de contexto. Esta estructura responde a la evidencia de que el rendimiento fotovoltaico y los patrones de demanda dependen fuertemente tanto de las condiciones ambientales como de los ritmos de uso asociados al calendario [20]. Las variables meteorológicas del sistema integran datos provenientes de APIs de pronóstico y reanálisis meteorológico, que se emplean tanto para alimentar los modelos de predicción como para mostrar información contextual en el tablero. Entre las variables empleadas se encuentran: temperatura del aire a 2 m, humedad relativa, velocidad del viento a 10 m, nubosidad total e irradiancia o radiación de onda corta incidente. Estas magnitudes son estándar en los modelos de predicción de potencia fotovoltaica, ya que capturan efectos térmicos, ópticos y convectivos sobre los módulos FV [18].

Las variables eléctricas de generación, consumo y almacenamiento en el módulo de telemetría y el repositorio de datos almacenan series temporales de: potencia fotovoltaica generada (kW) y energía diaria acumulada (kWh), potencia demandada por las cargas de la microrred y energía consumida, estado de carga (SoC) y potencia de carga/descarga de las baterías y eventos de conmutación de grupos diésel u otras fuentes de respaldo, cuando existan. Para el entrenamiento de los modelos, se emplean datasets con lecturas horarias o subhorarias de consumo (por ejemplo, medidores de campus universitario) y de producción FV, que se agregan y limpian siguiendo buenas prácticas de preparación de datos para series temporales energéticas [20].

Las variables temporales y de calendario en los modelos de consumo y parte de la lógica de predicción incorporan características derivadas del tiempo: hora del día, día de la semana, mes y semana del año, indicadores binarios como “día hábil”, “fin de semana”, “hora pico”, “hora nocturna” o “horario laboral”, representaciones cíclicas de la hora y el mes (transformaciones seno/coseno) para capturar patrones periódicos. La inclusión de estas variables está alineada con la literatura de pronóstico energético, que demuestra mejoras sostenidas cuando se combinan señales meteorológicas y patrones de calendario en un mismo modelo [18]. Conjuntamente, estas variables permiten que el

gemelo digital represente el estado de la microrred, anticipe su comportamiento y contextualice las recomendaciones operativas.

2.2.3 Fundamentos de los modelos de IA seleccionados

Para contextualizar la selección de modelos presentada en la siguiente sección, es pertinente definir los algoritmos de inteligencia artificial empleados. Un algoritmo de aprendizaje automático (Machine Learning) es un conjunto de instrucciones y reglas que permite a un sistema informático aprender patrones y tomar decisiones a partir de datos, en lugar de ser programado explícitamente para cada tarea [41]. El sistema se "entrena" exponiéndolo a un gran volumen de datos históricos, ajustando sus parámetros internos para minimizar el error en sus predicciones. Este proyecto emplea dos tipos principales de aprendizaje supervisado: regresión (predecir un valor numérico) y clasificación (predecir una categoría).

Random Forest (Bosques Aleatorios)

El algoritmo de Random Forest es un método de *aprendizaje conjunto* (ensemble) utilizado tanto para regresión como para clasificación. Su funcionamiento se basa en construir una multitud de árboles de decisión durante el entrenamiento [42]. Cada árbol individual se entrena con una muestra aleatoria de los datos (técnica conocida como *bootstrapping*) y, en cada nodo del árbol, solo considera un subconjunto aleatorio de las variables (features). Para una tarea de regresión, como predecir la generación o el consumo, la predicción final del "bosque" es el promedio de las predicciones de todos los árboles individuales [43].

Esta arquitectura lo hace ideal para el dominio energético por varias razones:

1. Manejo de no linealidad: Es capaz de capturar relaciones complejas y no lineales entre las variables meteorológicas (como irradiancia y temperatura) y la producción fotovoltaica, algo que modelos lineales simples no pueden hacer [42].
2. Robustez y precisión: Al promediar muchos árboles independientes, reduce drásticamente el sobreajuste (*overfitting*) y es robusto frente al ruido en los datos, un problema común en la telemetría de sensores [43].

3. Alto desempeño: Estudios comparativos demuestran que Random Forest exhibe un rendimiento superior o altamente competitivo para el pronóstico a corto plazo de la radiación solar y de la demanda eléctrica (STLF), superando a menudo a otros modelos cuando se alimenta con variables temporales y meteorológicas bien diseñadas [44].

Redes Neuronales Convolucionales (CNN)

Una Red Neuronal Convolucional (CNN) es un tipo de algoritmo de *aprendizaje profundo* (Deep Learning) diseñado específicamente para procesar y analizar datos visuales, como imágenes [45]. Su arquitectura está inspirada en el córtex visual humano y funciona aplicando una serie de filtros (capas convolucionales) para detectar jerárquicamente patrones en una imagen [46]. Las primeras capas aprenden a reconocer características simples, como bordes y texturas, mientras que las capas más profundas combinan estas características para identificar formas y objetos complejos.

Su idoneidad para la clasificación de la limpieza de paneles solares en este proyecto se fundamenta en:

1. Extracción automática de características: A diferencia de otros métodos, una CNN aprende por sí misma qué características visuales (p. ej., opacidad por polvo, manchas de suciedad, reflejos de un panel limpio) son relevantes para distinguir entre una imagen "limpia" y una "sucia" [47].
2. Estado del arte en visión por computador: Las CNN son el estándar de oro para tareas de clasificación de imágenes, logrando precisiones muy altas.
3. Aplicación en mantenimiento predictivo: La literatura científica valida el uso de CNN para la inspección de plantas fotovoltaicas, demostrando su alta eficacia (con precisiones reportadas superiores al 96 %) en la categorización específica de suciedad (*soiling*) en los módulos [47]. Esto automatiza una tarea de mantenimiento predictivo clave para evitar pérdidas de rendimiento.

2.2.4 Modelos de inteligencia artificial incorporados

El módulo de analítica e IA integra varios modelos que se apoyan en los datos descritos anteriormente y se exponen como servicios dentro del gemelo digital.

1. Modelo de predicción de generación fotovoltaica: Para estimar la potencia FV horaria se emplea un modelo de bosques aleatorios (Random Forest Regressor), entrenado sobre un conjunto de datos que combina irradiancia, temperatura, humedad relativa, velocidad del viento, nubosidad y variables temporales. Los bosques aleatorios resultan adecuados para este dominio porque capturan relaciones no lineales entre las variables meteorológicas y la producción, son robustos frente a ruido y datos atípicos y muestran buen desempeño en estudios recientes de pronóstico fotovoltaico basados en datos.
2. Modelo de predicción de consumo eléctrico: De forma análoga, la demanda se estima con un modelo de Random Forest entrenado a partir de registros de medidores reales, enriquecidos con variables de calendario y etiquetas horarias (horas pico, fines de semana, horarios lectivos). Este enfoque sigue la tendencia de usar modelos de aprendizaje automático sobre pipelines bien definidos de datos, que incluyen ingeniería de características, validación cruzada y monitorización posterior, como recomiendan trabajos recientes de MLOps aplicados a energía.
3. Modelo de estimación de autonomía de baterías: El sistema incorpora un servicio de estimación de autonomía que combina, predicciones de generación y consumo en un horizonte de 24 horas, capacidad nominal y límites operativos de las baterías y estado de carga actual y flujo de potencia previsto. A partir de esta información, el servicio estima el tiempo hasta alcanzar umbrales críticos, información clave para la operación segura en modo isla y para planificar el uso de grupos de respaldo.
4. Clasificador de limpieza de paneles a partir de imágenes: Además de los modelos de series temporales, el gemelo integra una red neuronal convolucional entrenada sobre imágenes de módulos FV etiquetadas como “limpio” o “sucio”. El modelo recibe imágenes preprocesadas a una resolución fija y emite probabilidades

asociadas a cada clase, que se presentan en la interfaz como un indicador de estado de limpieza. Este componente se inspira en trabajos que emplean redes convolucionales para detectar suciedad y polvo en paneles fotovoltaicos, demostrando que las arquitecturas CNN pueden alcanzar altas precisiones en la clasificación de paneles limpios y sucios y servir como soporte a estrategias de mantenimiento [48], [49].

En conjunto, estos modelos refuerzan el carácter “inteligente” del gemelo digital, al permitir no solo visualizar el estado actual, sino anticipar comportamientos y apoyar decisiones de limpieza, operación y mantenimiento.

2.2.5 Visualización y analítica en la plataforma web

El módulo de interfaz web organiza la información del gemelo digital en un tablero estructurado por tarjetas de indicadores, gráficos de series temporales, componentes de estado y widgets meteorológicos.

Entre los elementos principales se encuentran:

- Tarjetas de métricas (KPIs) que resumen, para el horizonte actual o diario, indicadores como energía generada, energía consumida, balance neto, porcentaje de uso de baterías y energía no suministrada evitada.




Figura 2: Gráfico de Generación

- Gráfico combinado de producción y consumo que muestra, sobre una misma línea de tiempo, la potencia FV y la demanda, junto con las predicciones de los modelos de IA. Esta visualización permite identificar desajustes, picos de demanda y márgenes de operación antes de que ocurran.
- Indicadores de estado de baterías, representados mediante diagramas circulares o barras que informan potencia de carga/descarga y autonomía estimada.



Figura 3: Gráfico de Generación vs Consumo

- Widgets meteorológicos que presentan el tiempo actual y el pronóstico en los próximos días, vinculados a la lógica de predicción de generación.




Figura 4: Datos Climáticos

- Vistas de inventario de activos, donde se listan paneles, strings, bancos de baterías y apagones programados con sus parámetros principales.




Figura 5: Dashboard De Administración

El uso de gráficos de líneas para series temporales, apoyados en tarjetas de KPIs y visualizaciones compactas para el estado de activos, responde a las recomendaciones para paneles de control de energía, donde se busca facilitar la identificación rápida de tendencias, anomalías y situaciones de riesgo. Los trabajos recientes sobre gemelos digitales para gestión energética también destacan la importancia de tableros interactivos que integren métricas, predicciones y escenarios, como parte del ciclo medir–predecir–actuar.

2.2.6 Funcionalidades principales del sistema

A partir de los módulos y datos descritos, el gemelo digital web ofrece un conjunto de funcionalidades principales del sistema que a su vez se derivan directamente del problema científico y del objetivo general planteado en la investigación. Entre ellas se destacan:

1. **Monitoreo en tiempo casi real:** Visualización de potencia generada por los paneles FV, consumo de la microrred y estado de carga de las baterías. Representación gráfica de series temporales y estados actuales en dashboards web.

2. **Gestión de datos históricos:** Almacenamiento de telemetría de producción, consumo y clima en una base de datos de series temporales. Acceso a históricos para análisis de tendencias, comparación de días y evaluación de desempeño.
3. **Pronóstico de generación y consumo:** Ejecución de modelos de predicción de generación fotovoltaica a corto plazo, integrando información meteorológica y datos históricos. Modelos de pronóstico de consumo que permiten estimar la demanda futura de la microrred.
4. **Estimación de autonomía y gestión del almacenamiento:** Cálculo de escenarios de autonomía de la microrred en función del estado de carga de las baterías, la generación prevista y los perfiles de consumo. Apoyo a decisiones sobre cuándo cargar o descargar baterías y cómo prepararse para eventos de apagón o baja generación.
5. **Detección temprana de anomalías y soporte al mantenimiento:** Identificación de comportamientos atípicos en la generación o en el consumo que puedan asociarse a fallos o degradación de componentes. Posibilidad de integrar, en etapas posteriores, modelos de clasificación de limpieza de paneles basados en imágenes para apoyar el mantenimiento preventivo.
6. **Gestión de usuarios y acceso:** Módulo básico de autenticación y autorización con roles diferenciados (por ejemplo, administrador y usuario estándar). Control de acceso a funcionalidades críticas, como modificación de configuración o parámetros del sistema.
7. **Analítica y métricas de desempeño:** Cálculo de indicadores energéticos (energía diaria generada y consumida, balance energético, energía no suministrada estimada) y otros indicadores de impacto asociados a la sustitución de generación diésel.

Estas funcionalidades se integran en una experiencia unificada, de forma que el operador pueda revisar el estado del sistema, anticipar su comportamiento, detectar problemas y evaluar alternativas operativas desde una misma plataforma.

2.3 Requisitos del sistema, problemas frecuentes y atributos de calidad

La formalización de requisitos traduce las necesidades identificadas en la introducción y el marco teórico en compromisos concretos de diseño y desarrollo. Se distinguen requisitos funcionales, que describen lo que el sistema debe hacer, y requisitos no funcionales, que especifican las propiedades de calidad deseadas (rendimiento, fiabilidad, seguridad, usabilidad, entre otras), siguiendo la clasificación recomendada en la literatura de ingeniería de software [50].

2.3.1 Requisitos funcionales

A continuación, se enumeran los requisitos funcionales (RF) del gemelo digital web. Se agrupan por áreas de funcionalidad, en coherencia con los módulos descritos.

Gestión de datos y activos

- RF-01. El sistema debe permitir registrar, consultar, actualizar y eliminar activos de la microrred, incluyendo paneles fotovoltaicos, bancos de baterías y puntos de medición.
- RF-02. El sistema debe almacenar series temporales de generación, consumo y estado de carga, con resolución al menos horaria, preservando fecha y hora de cada registro.

Integración meteorológica y pronósticos

- RF-03. El sistema debe integrar datos meteorológicos actuales y de pronóstico mediante servicios externos, incorporando al menos temperatura, humedad, nubosidad, velocidad del viento e irradiancia.
- RF-04. El sistema debe exponer un servicio de pronóstico de generación fotovoltaica horaria para un horizonte configurable (por ejemplo, 24 horas), basado en modelos de IA entrenados sobre datos históricos.
- RF-05. El sistema debe exponer un servicio de pronóstico de consumo eléctrico horario para un horizonte configurable, apoyado en modelos de IA entrenados con series de carga reales.

Simulación operativa y soporte a decisiones

- RF-06. El sistema debe estimar la autonomía de las baterías, calculando el tiempo hasta alcanzar umbrales mínimos de SoC bajo distintos escenarios de generación, demanda y apagones programados.
- RF-07. El sistema debe generar alertas cuando la autonomía prevista sea inferior a un umbral configurable o cuando se prevean desequilibrios significativos entre generación y consumo.

Mantenimiento y análisis de estado de paneles

- RF-08. El sistema debe permitir cargar imágenes de paneles fotovoltaicos y devolver una clasificación en términos de estado de limpieza (por ejemplo, “limpio” / “sucio”) acompañada de una medida de confianza.
- RF-09. El sistema debe mantener un histórico de resultados de clasificación de paneles para analizar su impacto en el rendimiento energético.

Visualización y experiencia de usuario

- RF-10. El sistema debe proporcionar un tablero web que muestre, en una sola vista, indicadores clave de rendimiento, series temporales de generación y consumo, estado de baterías y condiciones meteorológicas.
- RF-11. El sistema debe permitir seleccionar intervalos de tiempo para el análisis (por ejemplo, día, semana, mes) y filtrar los datos por tipo de variable (generación, consumo, SoC, etc.).
- RF-12. El sistema debe ofrecer vistas específicas para el inventario de activos y para la gestión de apagones programados.

Seguridad y gestión de usuarios

- RF-13. El sistema debe proporcionar mecanismos de registro e inicio de sesión de usuarios, con almacenamiento seguro de credenciales.
- RF-14. El sistema debe distinguir al menos entre un rol administrador (con capacidad de gestión de activos y configuración) y un rol usuario estándar (con acceso a visualización y consulta).

2.3.2 Requisitos no funcionales

Los requisitos no funcionales (RNF) se han definido tomando como referencia el modelo de calidad ISO/IEC 25010, que organiza la calidad del producto software en características como fiabilidad, eficiencia de desempeño, seguridad, usabilidad y mantenibilidad [51].

Eficiencia de desempeño

- RNF-01. El tiempo de respuesta de las operaciones de lectura de datos y visualización principal no debe superar los 2 segundos bajo condiciones de carga nominal.
- RNF-02. El sistema debe ser capaz de gestionar la visualización y el análisis de al menos un año de datos horarios sin deterioro apreciable del rendimiento.

Fiabilidad y disponibilidad

- RNF-03. El sistema debe tolerar fallos temporales en las APIs meteorológicas manteniendo un nivel mínimo de servicio mediante datos de respaldo o generación sintética de series meteorológicas.
- RNF-04. La arquitectura debe facilitar niveles de disponibilidad adecuados para un entorno académico y de laboratorio, permitiendo que el sistema esté operativo durante las actividades docentes y de investigación planificadas.

Usabilidad

- RNF-05. La interfaz debe ser utilizable por usuarios sin formación avanzada en sistemas eléctricos, presentando conceptos clave (producción, consumo, autonomía, pronóstico) con terminología clara y ayudas contextuales.
- RNF-06. Las visualizaciones deben ser legibles en pantallas de tamaño medio (por ejemplo, proyectores o monitores de aula), evitando sobrecarga de información en una sola vista.

Seguridad

- RNF-07. Las credenciales de usuario deben almacenarse empleando algoritmos de hash robustos, evitando el almacenamiento de contraseñas en texto plano.
- RNF-08. El sistema debe controlar el acceso a operaciones sensibles (como edición de activos o apagones) en función del rol del usuario autenticado, en línea con las recomendaciones de ciberseguridad para sistemas de monitorización energética.

Mantenibilidad y evolución

- RNF-09. La organización en módulos debe permitir sustituir o actualizar los modelos de IA sin alterar de forma significativa la interfaz de usuario, limitando los cambios a los servicios internos.
- RNF-10. El sistema debe documentar sus servicios y modelos principales, incluyendo variables de entrada y salida, métricas de desempeño y supuestos de diseño, facilitando su reutilización y extensión.

Portabilidad

- RNF-11. El backend debe poder desplegarse en entornos de laboratorio y en servidores de la universidad con cambios mínimos de configuración.
- RNF-12. El frontend web debe ser accesible desde navegadores modernos sin requerir complementos propietarios.

2.3.3 Problemas frecuentes y riesgos a mitigar

El diseño del gemelo digital busca anticipar una serie de problemas frecuentes en proyectos que combinan datos, modelos de IA y visualización energética.

1. Calidad y disponibilidad de datos: La presencia de huecos, inconsistencias o cambios en los esquemas de datos puede degradar el desempeño de los modelos y generar visualizaciones engañosas. Para mitigarlo, el sistema incluye mecanismos de generación de datos sintéticos cuando no existen sensores, validaciones de rangos y estructuras y una separación clara entre datasets de entrenamiento y datos operativos.

2. Deriva de modelos de IA y obsolescencia: A medida que cambian los patrones de consumo o se modifica la configuración de la microrred, los modelos pueden perder precisión. La literatura reciente en MLOps para energía subraya la importancia de monitorizar desempeño, detectar deriva y programar reentrenamientos controlados. En este proyecto, se preparan pipelines reproducibles y se registran métricas de error, lo que facilitará la actualización periódica de los modelos.
3. Latencia y robustez de servicios externos: Los servicios meteorológicos externos introducen latencia y posibles fallos de red. El diseño incorpora caché de pronósticos, mecanismos de reintento y estrategias de “fallback” para mantener funcionalidad básica cuando las APIs no están disponibles.
4. Ciberseguridad y exposición de datos: La exposición de datos operativos de la microrred y de credenciales de usuario requiere contemplar amenazas como accesos no autorizados o ataques a la API. Revisiones recientes sobre mantenimiento predictivo y ciberseguridad en plantas solares resaltan la necesidad de controles de acceso, registro de eventos y segmentación de redes. El sistema aborda estos aspectos mediante autenticación, roles y separación entre frontend y backend.
5. Complejidad de la interfaz y sobrecarga de información: Los tableros de control pueden resultar abrumadores si muestran demasiadas métricas a la vez. Estudios de dashboards para sistemas energéticos y gemelos digitales recomiendan usar narrativas visuales simples, apoyadas en series temporales, KPIs y vistas de alto nivel, con capacidad de “drill-down” cuando sea necesario. La solución propuesta prioriza una vista principal con indicadores esenciales y gráficos clave, dejando detalles avanzados para vistas específicas.

2.3.4 Atributos de calidad objetivos del diseño

Los atributos de calidad priorizados para el gemelo digital se inspiraron en modelos de referencia como ISO/IEC 25010 y en la literatura de arquitectura de software orientada a atributos de calidad. La definición explícita de estos atributos de calidad guía las

decisiones de diseño arquitectónico que se abordarán en las siguientes secciones del capítulo, donde se detallan la arquitectura candidata, los estilos y patrones aplicados y los mecanismos específicos adoptados para satisfacer los requisitos funcionales y no funcionales del sistema [50].

Atributo de calidad	Descripción en el contexto del sistema
Funcionalidad	El sistema proporciona las funciones necesarias para monitoreo, predicción, análisis y mantenimiento.
Rendimiento	El tiempo de respuesta de consultas y visualizaciones es adecuado para operación de monitoreo.
Fiabilidad	El sistema mantiene un comportamiento estable durante las sesiones de uso, sin fallos críticos.
Usabilidad	La interfaz presenta información de forma clara y coherente para usuarios técnicos.
Seguridad	Se protege el acceso a datos y funciones mediante autenticación y control básico de permisos.
Mantenibilidad	La estructura modular del código facilita la corrección de errores y la incorporación de mejoras.
Escalabilidad	Es posible ampliar el sistema (más sensores, modelos o usuarios) sin rediseñar su núcleo.
Portabilidad	La solución puede desplegarse en entornos de laboratorio de la CUJAE con herramientas libres.

Tabla 4: Atributos de calidad

2.4 Diagrama de casos de uso del sistema

El gemelo digital web se modela, desde la vista de casos de uso, como un sistema orientado al operador de la microrred fotovoltaica aislada. El actor principal es el **Operador**, que representa a la persona encargada de supervisar el comportamiento del sistema energético y tomar decisiones cotidianas de operación. A través de la interfaz web, el operador puede consultar las condiciones meteorológicas actuales, revisar la generación y el consumo de energía, analizar datos históricos, verificar el estado de los paneles fotovoltaicos e iniciar sesión para acceder a funcionalidades protegidas.

Sobre este rol se define el actor **Administrador**, que hereda las capacidades del operador y añade permisos para gestionar la información estructural del sistema: alta, baja y actualización de equipos instalados, así como administración de usuarios y de sus roles. Finalmente, se modela un tercer actor, **API Clima (Servicio Externo)**, que representa al proveedor externo de información meteorológica. En este caso, es el caso de uso “Consultar Condiciones Meteorológicas Actuales” el que inicia la comunicación con el servicio externo para solicitar los datos necesarios, reflejando la dependencia del gemelo digital respecto a fuentes de datos climáticos en línea. La Figura X ilustra estas interacciones a alto nivel mediante el diagrama de caso de uso del sistema.




Figura 6: Diagrama de Casos de Uso

2.4.1 Descripción de Casos de Uso

Caso de uso 1: Consultar Condiciones Meteorológicas Actuales

Campo	Descripción
Caso de uso	Consultar Condiciones Meteorológicas Actuales
Actores	Operador, API Clima (Servicio Externo)
Descripción	El operador solicita desde la interfaz web las condiciones meteorológicas actuales para la ubicación de la microrred. El

	sistema envía una petición a la API de clima, recibe variables como temperatura, humedad relativa, nubosidad, velocidad del viento e irradiancia, y las presenta en el tablero principal junto con la hora de actualización.
Requisitos funcionales	RF-03, RF-10, RF-11
Casos de uso asociados	Iniciar Sesión
Precondiciones	El usuario debe estar autenticado como operador o administrador y el servicio de API meteorológica debe estar disponible.
Postcondiciones	Las condiciones meteorológicas actuales quedan visibles en el tablero y pueden ser usadas por otros módulos (por ejemplo, el pronóstico de generación).

Caso de uso 2: Consultar Consumo Estimado

Campo	Descripción
Caso de uso	Consultar Consumo Estimado
Actores	Operador
Descripción	El operador selecciona un horizonte temporal (por ejemplo, próximas 24 horas) y solicita la estimación de consumo eléctrico. El sistema invoca los modelos de IA de pronóstico de demanda, genera la serie temporal de consumo esperado y la muestra en gráficos y métricas resumidas (energía prevista, picos de demanda, etc.).
Requisitos funcionales	RF-02, RF-05, RF-06, RF-07, RF-10, RF-11
Casos de uso asociados	Iniciar Sesión
Precondiciones	El usuario debe estar autenticado y deben existir datos históricos de consumo suficientes para alimentar el modelo de pronóstico.

Postcondiciones	Se visualizan las curvas de consumo estimado y se actualizan indicadores derivados (por ejemplo, autonomía estimada de baterías y alertas de riesgo de desequilibrio).
-----------------	--

Caso de uso 3: Consultar Datos Históricos

Campo	Descripción
Caso de uso	Consultar Datos Históricos
Actores	Operador
Descripción	El operador selecciona un intervalo de fechas y las variables de interés (generación, consumo, estado de carga, clima) y solicita la visualización de históricos. El sistema recupera las series temporales almacenadas y las presenta en gráficos y tablas, permitiendo comparar periodos y analizar tendencias.
Requisitos funcionales	RF-02, RF-09, RF-10, RF-11
Casos de uso asociados	Iniciar Sesión
Precondiciones	El usuario debe estar autenticado y debe existir información histórica registrada en la base de datos.
Postcondiciones	Las series históricas solicitadas se muestran en la interfaz, quedando disponibles para exportación o para análisis complementarios dentro del sistema.

Caso de uso 4: Revisar Estado de Paneles

Campo	Descripción
Caso de uso	Revisar Estado de Paneles
Actores	Operador
Descripción	El operador sube o selecciona imágenes de los arreglos fotovoltaicos o accede a las últimas capturas registradas. El

	sistema ejecuta el modelo de clasificación de imágenes para determinar si los paneles se encuentran limpios o sucios, relaciona los resultados con el rendimiento energético observado y presenta un resumen por string o conjunto de paneles.
Requisitos funcionales	RF-01, RF-08, RF-09, RF-10, RF-11
Casos de uso asociados	Iniciar Sesión
Precondiciones	El usuario debe estar autenticado, deben existir paneles registrados en el inventario y el modelo de clasificación de imágenes debe estar disponible.
Postcondiciones	Se actualiza el estado de limpieza de los paneles y se registran los resultados de clasificación para análisis históricos y decisiones de mantenimiento.

Caso de uso 5: Iniciar Sesión

Campo	Descripción
Caso de uso	Iniciar Sesión
Actores	Operador, Administrador
Descripción	El usuario introduce sus credenciales en la interfaz de acceso. El sistema verifica la identidad mediante los mecanismos de autenticación definidos, asigna el rol correspondiente (operador o administrador) y habilita las funcionalidades asociadas a dicho rol.
Requisitos funcionales	RF-13, RF-14
Casos de uso asociados	Caso base requerido para el resto de casos de uso interactivos con datos protegidos.
Precondiciones	El usuario debe estar previamente registrado en el sistema y la base de datos de credenciales debe estar disponible.

Postcondiciones	El usuario queda autenticado en la sesión actual con el rol que le corresponde y se registra el evento de inicio de sesión.
-----------------	---

Caso de uso 6: Consultar Generación de Energía

Campo	Descripción
Caso de uso	Consultar Generación de Energía
Actores	Operador
Descripción	El operador solicita la visualización de la generación de energía de la microrred para el instante actual y para un periodo reciente. El sistema muestra potencia instantánea, energía diaria acumulada y, cuando está disponible, pronósticos de generación basados en modelos de IA y datos meteorológicos.
Requisitos funcionales	RF-02, RF-04, RF-06, RF-07, RF-10, RF-11
Casos de uso asociados	Iniciar Sesión, Consultar Condiciones Meteorológicas Actuales
Precondiciones	El usuario debe estar autenticado y deben existir datos de generación registrados y, en su caso, modelos de pronóstico entrenados.
Postcondiciones	Se actualizan las gráficas de generación y los indicadores clave (por ejemplo, energía generada en el día y comparación con el consumo).

Caso de uso 7: Gestionar Equipos Instalados

Campo	Descripción
Caso de uso	Gestionar Equipos Instalados
Actores	Administrador
Descripción	El administrador registra, modifica o elimina información de activos de la microrred, como arreglos fotovoltaicos, bancos de baterías,

	inversores y puntos de medición. También puede asociar apagones programados u otros eventos relevantes a estos activos.
Requisitos funcionales	RF-01, RF-02, RF-12, RF-14
Casos de uso asociados	Iniciar Sesión
Precondiciones	El usuario debe estar autenticado como administrador y la base de datos de activos debe estar accesible.
Postcondiciones	Se actualiza el inventario de equipos instalados y los cambios quedan disponibles para el resto de módulos (pronóstico, simulación y visualización).

Caso de uso 8: Gestionar Usuarios

Campo	Descripción
Caso de uso	Gestionar Usuarios
Actores	Administrador
Descripción	El administrador crea, actualiza o desactiva cuentas de usuario del sistema, asignando roles (operador, administrador u otros que se definan) y gestionando información básica de perfil. También puede restablecer contraseñas o revocar accesos cuando sea necesario.
Requisitos funcionales	RF-13, RF-14
Casos de uso asociados	Iniciar Sesión
Precondiciones	El usuario debe estar autenticado como administrador y debe existir conectividad con la base de datos de usuarios.

Postcondiciones	Se actualiza la configuración de cuentas y roles, lo que impacta en el control de acceso a las distintas funcionalidades del gemelo digital web.
-----------------	--

2.4.1 Diagrama de Actividades de Consultar Generación de Energía




Figura 7 Diagrama de Actividades

2.5 Arquitectura candidata del sistema

La arquitectura de software define la organización fundamental de un sistema, sus componentes y las relaciones entre ellos. De acuerdo con el estándar ISO/IEC/IEEE 42010, una arquitectura debe describirse mediante vistas que respondan a las preocupaciones de los distintos interesados y que sirvan como base para analizar atributos de calidad como rendimiento, mantenibilidad y seguridad [52], [53]. En el caso del gemelo digital web, la arquitectura candidata debe ser coherente con los atributos de calidad priorizados en la sección 2.3.4 y con las restricciones de un entorno universitario y de microrred aislada.

Desde esta perspectiva, la arquitectura propuesta se apoya en un modelo cliente–servidor web en el que el cliente (interfaz web) gestiona la interacción con el usuario y el servidor concentra la lógica de negocio, el acceso a datos y los servicios de analítica e

IA. Este patrón se ha consolidado como uno de los pilares del diseño de sistemas distribuidos, al permitir centralizar el procesamiento y el almacenamiento y simplificar la gestión de recursos, mientras múltiples clientes acceden a los servicios a través de solicitudes de red [53], [54].

2.5.1 Criterios de selección arquitectónica

Para seleccionar la arquitectura candidata se consideraron los siguientes criterios, alineados con los requisitos y el contexto del proyecto. El sistema debe ser implementable en el marco de una tesis de pregrado, con un equipo reducido y recursos de infraestructura limitados. Esto favorece arquitecturas de menor complejidad operativa frente a alternativas distribuidas de gran escala. La estructura debe facilitar la evolución del sistema (incorporación de nuevos modelos de IA, ampliación de tipos de datos o visualizaciones) manteniendo una separación clara entre módulos de dominio (telemetría, predicción, inventario, mantenimiento). Si bien el despliegue inicial se orienta a un entorno de laboratorio, la solución debe poder crecer a más usuarios, más puntos de medición y nuevos casos de uso sin exigir un rediseño completo. La arquitectura debe soportar las funciones clave del gemelo digital (ingesta de datos, modelos de simulación y predicción, visualización y gestión de configuración) y alinearse con las necesidades de integración futuras planteadas en el marco teórico. Debe ser posible razonar explícitamente sobre rendimiento, fiabilidad, seguridad y portabilidad, aplicando buenas prácticas de arquitectura orientada a atributos de calidad.

2.5.2 Arquitectura candidata seleccionada

Considerando los criterios anteriores y el alcance del proyecto, se adopta como arquitectura candidata un monolito modular de tipo cliente–servidor web, estructurado en capas lógicas coherentes con la referencia a plataformas IoT y de observabilidad estudiadas en el Marco Teórico.

En términos conceptuales, la arquitectura se organiza del siguiente modo:

Capa de presentación (cliente web): Interfaz desarrollada como aplicación web que presenta paneles de visualización, formularios de gestión y vistas especializadas para la exploración de datos y resultados de los modelos de IA. Este cliente se comunica exclusivamente con el backend mediante APIs bien definidas (GraphQL y un pequeño conjunto de endpoints REST), respetando la separación de responsabilidades entre presentación y lógica de negocio.

Capa de servicios de aplicación (backend): Implementa los casos de uso descritos en el epígrafe 2.4 a través de módulos de dominio: gestión de inventario de paneles y baterías, registro y consulta de telemetría, obtención y procesamiento de datos meteorológicos, generación de pronósticos, simulación de autonomía y gestión de apagones. Estos servicios exponen una interfaz unificada al frontend y encapsulan el acceso a la base de datos y a los modelos de IA.

Capa de analítica e IA: Aglutina los modelos de predicción de generación, consumo y estimación de autonomía, así como el clasificador de limpieza de paneles. Desde el punto de vista arquitectónico, estos modelos se presentan al resto del sistema como servicios invocables, lo que permite reemplazarlos o extenderlos en el futuro sin afectar al contrato que exponen hacia el frontend.

Capa de persistencia y configuración: Gestiona el almacenamiento de series temporales, inventario de activos, resultados de clasificación y parámetros de configuración del sistema. Esta capa garantiza que tanto el dashboard como los modelos de IA trabajen con una visión consistente de la microrred.

La comunicación entre el cliente y el servidor sigue el patrón de arquitectura cliente–servidor descrito más adelante, en el cual el cliente realiza solicitudes y el servidor responde centralizando el procesamiento y la gestión de datos [54]. Este patrón es ampliamente utilizado en aplicaciones web y gemelos digitales energéticos, donde los clientes solo necesitan un navegador mientras el servidor aloja los componentes más pesados.

2.6 Estilos y patrones arquitectónicos

El gemelo digital web se apoya en una combinación de estilos y patrones arquitectónicos que estructuran el sistema y orientan sus atributos de calidad. En la literatura se entiende por estilo arquitectónico una familia de arquitecturas que comparten organización, tipos de componentes y conectores, mientras que un patrón arquitectónico describe soluciones recurrentes a problemas típicos de organización del software dentro de ese marco. Fuentes clásicas sobre arquitectura de software clasifican los estilos en familias como flujo de datos, centrados en datos y llamada–retorno, cada una asociada a ciertos atributos de calidad (modificabilidad, desempeño, integrabilidad, etc.). Por su parte, los patrones de diseño documentados en repositorios como Refactoring.Guru se utilizan para refinar la estructura interna, mejorar la mantenibilidad y proporcionar un lenguaje común al equipo de desarrollo [55].

En este proyecto destacan tres combinaciones principales:

1. El estilo Llamada y Retorno materializado mediante los patrones Cliente–Servidor y N-Capas,
2. El estilo Centrado en Datos mediante el patrón Repositorio, y
3. El estilo de Flujo de Datos a través del patrón Tuberías y Filtros para procesos del backend.

Cada uno de estos estilos se describe a continuación, enfatizando su aplicación concreta al gemelo digital web.


2.6.1 Estilo Llamada y Retorno. Patrones Cliente–Servidor y N-Capas


El estilo Llamada y Retorno organiza el sistema como un conjunto de componentes que se invocan mutuamente mediante llamadas explícitas, devolviendo el control al componente llamador una vez concluida la operación. Este enfoque favorece una estructura jerárquica clara y es la base de arquitecturas en capas, orientadas a objetos y sistemas cliente–servidor. En el gemelo digital web, este estilo se concreta principalmente a través del patrón Cliente–Servidor. Este patrón divide el sistema en un

servidor que ofrece servicios y recursos, y uno o varios clientes que formulan peticiones y consumen las respuestas. En el proyecto:

- El servidor corresponde al backend del gemelo digital, que implementa la lógica de negocio, los servicios de dominio (telemetría, predicción, inventario de activos, gestión de apagones) y el acceso a datos.
- El cliente es la aplicación web que ejecuta el Operador y el Administrador, encargada de mostrar dashboards, formularios y gráficos, y de enviar solicitudes al servidor para consultar o modificar información.

Esta separación permite que el servidor concentre la lógica crítica y la gestión de datos, mientras que el cliente se centra en la experiencia de usuario. Atributos como la modificabilidad y la portabilidad se benefician de este patrón, ya que la interfaz web podría cambiarse o evolucionar sin alterar la lógica central del gemelo digital, e incluso podrían desarrollarse clientes alternativos (por ejemplo, una aplicación móvil) sobre las mismas APIs.





Complementariamente, el sistema adopta el patrón N-Capas, que especializa el estilo Llamada y Retorno al estructurar el servidor en capas horizontales con responsabilidades bien delimitadas.

La arquitectura propuesta se fundamenta en un modelo de la **reutilización** de componentes y lógica de negocio.

Capa Específica (Consumidor de Reutilización)

- **Vistas:** Este paquete es el *consumidor* final de la reutilización. No es reutilizable en sí mismo, sino que se *construye reutilizando* los Componentes React para ensamblar las pantallas que ve el usuario. El framework **NextJS** proporciona la estructura base de la aplicación.

Capa General (Lógica de Negocio y Presentación)

Esta capa integra tanto la interfaz de usuario como los principales módulos de lógica de negocio, diseñados para ser unidades funcionales reutilizables:

- **Servicios de Machine Learning (ML):** Esta unidad funcional representa un conjunto de capacidades esenciales. Su división interna en paquetes (Generación, Limpieza, Consumo) permite la reutilización modular del *pipeline* de ML. Específicamente, otros módulos del sistema, como el **Servicio**

Climatológico, pueden **reutilizar** la capacidad de Generación del modelo para sus propios fines analíticos.

- **Servicio Climatológico:** Opera como un componente reutilizable que abstrae la complejidad de la obtención de datos climáticos, **reutilizando** la funcionalidad de Generación del ML.
- **CRUD Dispositivos:** Este módulo es un servicio específico y **reutilizable** que gestiona los datos de dispositivos. Se integra directamente con los componentes de la interfaz de usuario.
- **Componentes React:** Representan la máxima expresión de la reutilización en el *frontend*, siendo bloques de interfaz de usuario contruidos una única vez para ser ensamblados en las distintas Vistas.


Capa Intermedia (Servicios, API y Datos)

Esta capa es el punto de encuentro y orquestación, clave para la flexibilidad y reutilización de datos entre el *frontend* y los servicios de la capa general:

- **GraphQL:** Actúa como una fachada de API, unificando las fuentes de datos. Su diseño permite que los clientes (e.g., el *frontend*) **reutilicen** un único *endpoint* para solicitar datos consolidados. La arquitectura demuestra esta capacidad al **reutilizar** la información procesada del servicio de Limpieza de ML y al integrar el servicio externo **OpenMeteo API**.
- **FastAPI <<backend framework>>:** Se utiliza como la herramienta principal para la **construcción y exposición de APIs** reutilizables (RESTful), como la del CRUD Dispositivos. Este framework es el responsable de la interacción con el sistema de persistencia **MongoDB**.
- **MongoDB:** Proporciona un sistema de persistencia de datos NoSQL, un recurso que es **reutilizado** por los diversos servicios *backend* expuestos a través de FastAPI.

Capa de Servicios del Sistema

- Los protocolos **HTTPS** y **TCP/IP** constituyen la infraestructura de transporte estándar y universalmente **reutilizable** que garantiza la conectividad segura y fiable entre todos los componentes y servicios desacoplados.




Este patrón favorece la mantenibilidad y la reutilización, porque cada capa puede evolucionar de forma relativamente independiente siempre que se respeten las interfaces. Además, contribuye a la seguridad, al permitir concentrar las validaciones y controles de acceso en puntos bien definidos.

2.6.2 Estilo Centrado en Datos. Patrón Repositorio

El estilo centrado en datos se caracteriza por la existencia de un almacén de datos compartido que actúa como núcleo del sistema, mientras que los componentes restantes se organizan alrededor de dicho repositorio para leer, escribir y procesar información. En este estilo, la integridad y consistencia de los datos son objetivos prioritarios, y los componentes tienden a ser relativamente independientes entre sí, ya que interactúan principalmente a través del almacén central.

En el gemelo digital web, este estilo se materializa mediante el patrón arquitectónico Repositorio. El repositorio mantiene la información sobre inventario de paneles y baterías, y gestión de usuarios y permisos. Este patrón aporta varias ventajas relevantes para el proyecto al centralizar el acceso a los datos, se reduce la duplicidad y se facilita la aplicación de reglas de validación coherentes para toda la aplicación. La implementación física del repositorio (por ejemplo, cambios en el esquema de la base de datos o migraciones de tecnología) puede modificarse sin afectar a la lógica de negocio, siempre que se mantenga la interfaz del repositorio. El repositorio central facilita el registro histórico de predicciones, eventos de mantenimiento y cambios de configuración, requisito clave para evaluar el desempeño del gemelo digital a lo largo del tiempo. Entre los atributos en conflicto se encuentra el desempeño, ya que concentrar todas las operaciones en un único almacén puede convertirse en un cuello de botella si el volumen de datos crece significativamente. No obstante, en el contexto de una microrred aislada y un despliegue inicial en entorno universitario, esta solución ofrece un equilibrio adecuado entre complejidad y beneficios.




2.6.3 Estilo de Flujo de Datos. Patrón Tuberías y Filtros

El estilo de flujo de datos concibe el sistema como una secuencia de transformaciones sobre un flujo de información, donde cada etapa recibe datos, los procesa y entrega una salida a la siguiente. Un caso particular de este estilo es el patrón Tuberías y Filtros (Pipes and Filters), en el que cada filtro encapsula una transformación y las tuberías actúan como conectores que trasladan los datos entre filtros.

En el gemelo digital web, este patrón se aplica de forma interna a varios procesos del backend, especialmente en la preparación y análisis de datos para la inteligencia artificial. Algunos ejemplos son:


- **Flujo de datos para predicción de generación y demanda:**

1. Ingesta de datos históricos de generación, consumo y estado de carga.
2. Enriquecimiento con información meteorológica histórica y pronosticada.
3. Preprocesamiento y normalización de variables.
4. Ejecución de los modelos de aprendizaje automático para producir pronósticos.
5. Cálculo de métricas derivadas como autonomía estimada o indicadores de riesgo.



- **Flujo de datos para clasificación de limpieza de paneles:**

1. Recepción de la imagen enviada por el usuario.
2. Preprocesamiento (redimensionado, normalización).
3. Inferencia mediante la red convolucional.
4. Generación de una etiqueta (limpio/sucio) y, opcionalmente, de una puntuación asociada a la confianza.



En ambos casos, cada etapa puede verse como un filtro que transforma los datos y los entrega al siguiente filtro a través de una tubería lógica. Esta organización aporta:

- Modularidad y reusabilidad: es posible sustituir o mejorar un filtro (por ejemplo, cambiar el modelo de predicción) sin alterar el resto del flujo, siempre que se mantenga el formato de entrada y salida.
- Mantenibilidad: la división del procesamiento en pasos pequeños y bien definidos facilita la comprensión del sistema y la localización de errores.
- Escalabilidad interna: ciertas etapas computacionalmente intensivas podrían escalarse de forma independiente (ejecutando filtros en paralelo o en procesos separados) si el volumen de datos aumentara.

El principal atributo en conflicto es el desempeño, debido a la sobrecarga de pasar datos entre etapas cuando el flujo está muy fragmentado. Sin embargo, en el contexto actual, la granularidad elegida permite un buen equilibrio entre claridad de diseño y eficiencia.

En síntesis, la combinación de estilos Llamada–Retorno, Centrado en Datos y Flujo de Datos proporciona una base sólida para el gemelo digital web. Estos estilos, junto con los patrones Cliente–Servidor, N-Capas, Repositorio y Tuberías y Filtros, permiten razonar de forma estructurada sobre los atributos de calidad de la solución y preparan el terreno para los principios de diseño y patrones de diseño específicos que se abordarán en los epígrafes siguientes.

2.7 Principios y patrones de diseño

El diseño del gemelo digital web se guía por un conjunto de principios y patrones que buscan evitar síntomas clásicos de “pudrición del diseño”, como rigidez, fragilidad, inmovilidad y viscosidad, identificados en la literatura de ingeniería de software como indicadores de sistemas difíciles de modificar y reutilizar. Estos principios orientan la modularidad del backend, la organización de la interfaz web y la integración de los modelos de inteligencia artificial, y se complementan con patrones GRASP y patrones de diseño GoF ampliamente adoptados en el desarrollo orientado a objetos.

2.7.1 Principios generales de diseño

A nivel general se priorizan principios como alta cohesión, bajo acoplamiento, modularidad, encapsulamiento y separación entre interfaz e implementación, considerados fundamentales para lograr diseños comprensibles y mantenibles.

En el gemelo digital web, la cohesión se refuerza agrupando responsabilidades afines en módulos de dominio:

- un servicio de telemetría responsable de la consulta de series temporales de generación, consumo y estado de carga;
- un servicio de predicción que concentra la interacción con los modelos de aprendizaje automático y el cálculo de autonomía;
- un servicio de inventario encargado de paneles, baterías y activos de la microrred;
- un servicio de gestión de apagones y eventos operativos.

Esta organización reduce la probabilidad de “clases dios” y facilita que cada cambio afecte solo a un subconjunto del sistema [56].

El acoplamiento se limita definiendo contratos claros entre capas y módulos. La interfaz web solo interactúa con el backend a través de resolvers y endpoints; la lógica de dominio, a su vez, se apoya en una capa de acceso a datos que encapsula el detalle de la persistencia y de las APIs externas. Esto permite evolucionar la base de datos, cambiar

proveedores de clima o sustituir modelos de IA sin impactar a la interfaz. Asimismo, se aplican principios pragmáticos muy difundidos como DRY (Don't Repeat Yourself) y KISS (Keep It Simple, Stupid), que recomiendan evitar duplicación innecesaria y preferir soluciones simples frente a diseños excesivamente complejos en cuanto a ingeniería. En la práctica se centraliza, por ejemplo, la conversión de unidades y el formateo de fechas en utilidades reutilizables, y se tiende a componentes y servicios pequeños con responsabilidades bien definidas.

2.7.2 Principios SOLID en el gemelo digital

Entre los principios específicos de diseño orientado a objetos, se adopta el conjunto SOLID, introducido por Robert C. Martin como guía para obtener sistemas más flexibles y fáciles de mantener [57].

Principio de Responsabilidad Única (SRP): Cada módulo debe tener una única razón para cambiar. En el gemelo digital esto se refleja en la separación clara de servicios: el servicio de pronósticos se encarga exclusivamente de preparar y ejecutar modelos de IA; el servicio de inventario administra activos físicos. De manera análoga, en el frontend se diferencian componentes para gráficos, tarjetas de indicadores y formularios, evitando mezclar lógica de negocio con presentación.

Principio Abierto/Cerrado (OCP): Los módulos deben estar abiertos a extensión, pero cerrados a modificación. La lógica que orquesta las predicciones trabaja contra una interfaz genérica de “modelo de predicción”, de modo que es posible añadir nuevas estrategias (por ejemplo, incorporar una red neuronal además del modelo de Random Forest) sin modificar el código de los controladores ni de la interfaz web, siempre que se respete el contrato.

Principio de Sustitución de Liskov (LSP): Las implementaciones concretas deben poder sustituirse sin alterar el comportamiento observable del sistema. Esto guía el diseño de abstracciones como “proveedor de clima” o “motor de predicción”: distintas implementaciones pueden reemplazarse en tiempo de ejecución (p. ej., cambiar de una

API meteorológica a otra, o usar un modelo experimental) sin que el resto del sistema deba conocer los detalles internos.

Principio de Segregación de Interfaces (ISP): Es preferible tener varias interfaces pequeñas y específicas que una interfaz grande y genérica. En el backend se definen interfaces separadas para servicios de predicción, inventario, apagones y clasificación de imágenes, en lugar de agrupar todo en un único contrato voluminoso. Esta estrategia simplifica las dependencias y permite que cada cliente consuma solo las operaciones que necesita.

Principio de Inversión de Dependencia (DIP): Los módulos de alto nivel deben depender de abstracciones y no de implementaciones concretas. Los controladores de la API dependen de interfaces de servicio que se inyectan en tiempo de arranque con implementaciones concretas; esto facilita las pruebas con dobles (*mocks*) y reduce el acoplamiento a detalles tecnológicos específicos de la base de datos o de los modelos de IA.

La aplicación conjunta de estos principios contribuye a que el gemelo digital sea más robusto frente a cambios y a que su estructura pueda acompañar la evolución futura del proyecto sin rediseños radicales.

2.8 Reutilización y administración de la configuración

2.8.1 Estrategia de reutilización

La reutilización de software se entiende como el uso sistemático de artefactos ya existentes (requisitos, diseños, código, datos, pruebas) para construir nuevos sistemas con menor costo, tiempo y riesgo, concentrando el esfuerzo creativo en las particularidades del dominio. La literatura de ingeniería de software señala que los enfoques basados en reutilización tienden a mejorar la calidad y la productividad del desarrollo, siempre que se apoyen en una arquitectura modular y en una gestión disciplinada de la configuración.

En el gemelo digital web propuesto, la reutilización se ha planificado en varios niveles complementarios:

Reutilización a nivel de arquitectura y diseño: La adopción de un monolito modular cliente–servidor, con separación clara entre frontend, backend y capa de analítica/IA, permite definir puntos de extensión bien identificados (servicios de dominio, modelos de IA, vistas de interfaz). Este esquema es replicable en futuros proyectos de la CUJAE relacionados con microrredes o con otros gemelos digitales energéticos, manteniendo los mismos principios arquitectónicos y de diseño establecidos en el capítulo.

Reutilización a nivel de servicios y módulos de dominio: El backend se organiza en servicios para gestión de inventario (paneles y baterías), telemetría, clima, predicción, simulación de autonomía y gestión de apagones. Cada servicio encapsula reglas de negocio y acceso al repositorio de datos, de forma que pueda ser reutilizado en otros sistemas que compartan el mismo modelo de dominio (por ejemplo, laboratorios de microrredes en otros campus o proyectos docentes). La separación en módulos facilita importar servicios completos en nuevos contextos con modificaciones mínimas.

Reutilización de activos de datos y modelos de IA: Los conjuntos de datos preparados para entrenamiento (históricos de generación, demanda y clima), los *notebooks* de preprocesamiento y entrenamiento, y las métricas de evaluación asociadas se tratan como artefactos reutilizables. Esta organización permite reentrenar modelos con nuevos datos, comparar algoritmos y trasladar *pipelines* de MLOps a otras instalaciones FV, en línea con las recomendaciones recientes sobre pronóstico energético y gestión del ciclo de vida de modelos.

En la interfaz web también se promueve la reutilización mediante componentes genéricos de visualización (gráficos de series temporales, tarjetas de indicadores, tablas configurables) que pueden reutilizarse en nuevas vistas o proyectos sin reescribir la lógica de presentación. En conjunto, esta estrategia asegura que el gemelo digital no sea una solución puntual, sino una base evolutiva que facilite futuros desarrollos y experimentación en microrredes inteligentes dentro de la universidad.

2.8.2 Administración de la configuración

La administración de la configuración de software (Configuration Management) agrupa las actividades necesarias para identificar, controlar y hacer trazable la evolución de los elementos que componen un sistema: código fuente, datos, modelos, documentación y scripts de despliegue. Su objetivo principal es garantizar que el sistema pueda reconstruirse en cualquier momento a partir de versiones conocidas y coherentes, reduciendo errores y facilitando la colaboración.

En este proyecto, la administración de la configuración se organiza en tres ejes principales.

Gestión de versiones

La gestión de versiones es la base de la administración de la configuración, ya que permite conocer qué cambios se han realizado, por quién y en qué momento, así como revertir a estados anteriores en caso de errores. Los sistemas de control de versiones distribuidos, como Git, se han consolidado como estándar de facto para soportar trabajo colaborativo, *branching* y *merging* en proyectos de software.

En el gemelo digital web se utiliza Git sobre un repositorio remoto (GitHub), donde se versionan como elementos de configuración:

- el código fuente del backend y del frontend,
- los esquemas y scripts de base de datos,
- los *notebooks* de entrenamiento de modelos,
- archivos de configuración de servicios externos (API de clima, credenciales),
- documentación técnica relevante.

Cada nueva funcionalidad se desarrolla en ramas independientes, que luego se integran en la rama principal tras revisión y pruebas básicas, siguiendo buenas prácticas de control de versiones. Esta estrategia mejora la trazabilidad y permite reconstruir

versiones concretas del sistema, un aspecto crítico cuando se trabaja con modelos de IA sensibles a cambios en dependencias o conjuntos de datos.

Integración del sistema y coherencia entre módulos

La integración del sistema consiste en combinar de forma controlada los módulos desarrollados (servicios de dominio, modelos de IA, componentes de interfaz) en un producto ejecutable coherente. Las buenas prácticas recomiendan automatizar, en la medida de lo posible, los pasos de construcción y pruebas para reducir errores humanos y asegurar que el conjunto se mantiene en un estado funcional. En el gemelo digital se siguen criterios como declarar explícitamente las dependencias del backend (librerías de Python, frameworks web y de IA) y del frontend (framework React/Next.js y librerías de visualización) mediante archivos de requisitos y configuraciones reproducibles. Estructurar el repositorio en directorios coherentes (código de aplicación, datos de entrenamiento, *notebooks*, configuración), de forma alineada con la división en módulos de dominio descrita en la arquitectura. Utilizar ramas de integración intermedias para combinar cambios de diferentes desarrolladores, verificando su compatibilidad antes de fusionarlos en la rama principal. Estas prácticas facilitan la reconstrucción del sistema en distintas máquinas o entornos (laboratorio, servidor departamental) y contribuyen a la reproducibilidad de los experimentos con modelos de predicción.

Rastreo de errores y gestión de incidencias

El rastreo de errores completa la administración de la configuración al proporcionar un mecanismo para registrar incidencias, proponer mejoras y vincular cada corrección con uno o varios cambios específicos en el repositorio. Herramientas integradas en las propias plataformas de control de versiones (como sistemas de *issues* y *pull requests*) permiten documentar el ciclo de vida de cada incidencia, favoreciendo la coordinación del equipo y la trazabilidad [65][66].

En el contexto del gemelo digital, se recomienda utilizar el sistema de incidencias del repositorio remoto para registrar:

- errores funcionales (por ejemplo, fallos al registrar paneles o al visualizar pronósticos),
- problemas de rendimiento (latencias excesivas en la carga de dashboards o en la ejecución de modelos),
- incidencias de datos (valores atípicos, inconsistencias en series de telemetría o clima),
- deudas técnicas y mejoras pendientes.

Cada incidencia se asocia a una rama, uno o varios *commits* y, finalmente, a una solicitud de fusión (*pull request*), cerrándose únicamente cuando se han realizado las pruebas necesarias. Esto permite reconstruir el historial de decisiones y justifica los cambios en la base de código, reforzando la calidad del producto y el aprendizaje del equipo. En síntesis, la combinación de una estrategia explícita de reutilización y una administración disciplinada de la configuración refuerza la mantenibilidad, la reproducibilidad y la capacidad de evolución del gemelo digital, aspectos esenciales para su uso continuado como plataforma de experimentación académica y para su futura adaptación a microrredes reales.

2.9 Conclusiones parciales del capítulo 2

El capítulo 2 desarrolló el diseño conceptual y arquitectónico del gemelo digital web, mostrando cómo la problemática identificada en el Capítulo 1 se traduce en una solución de software coherente con las necesidades de una microrred fotovoltaica aislada y del contexto académico de la CUJAE. En primer lugar, la descripción general del sistema y de sus módulos permitió precisar el papel de cada componente: adquisición y gestión de datos operativos, servicios de dominio, analítica e inteligencia artificial, y una interfaz web orientada a la exploración y toma de decisiones. La caracterización de las variables meteorológicas y eléctricas, junto con los modelos de IA empleados (predicción de generación y demanda, estimación de autonomía, clasificación de suciedad), conectó directamente el diseño con los fundamentos técnicos revisados en el Capítulo 1. En segundo lugar, la especificación de requisitos funcionales y no funcionales, así como la identificación de problemas frecuentes y riesgos, proporcionó criterios de calidad

explícitos para el diseño: precisión de los modelos, tiempos de respuesta aceptables, robustez ante fallos de servicios externos, seguridad de los datos y facilidad de uso para operadores y usuarios académicos. Estos requisitos se apoyaron en referencias sobre gemelos digitales energéticos, buenas prácticas de evaluación y modelos de calidad de producto.

Sobre esa base, el diagrama de casos de uso estructuró las interacciones entre los actores (Administrador, Operador y API de clima) y el sistema, desde la autenticación hasta el monitoreo, las predicciones y la gestión de activos. Esta vista de escenarios se utilizó como puente hacia la arquitectura candidata, donde se justificó la elección de un monolito modular cliente–servidor frente a arquitecturas de microservicios, atendiendo a la escala del proyecto, el tamaño del equipo y las restricciones de infraestructura, sin renunciar a la extensibilidad futura. A continuación, el análisis de estilos y patrones arquitectónicos (cliente–servidor, n-capas, repositorio, tuberías y filtros) y de principios mostró cómo la solución se apoya en prácticas consolidadas de la ingeniería de software para mejorar mantenibilidad, flexibilidad y claridad estructural. Estas decisiones permiten razonar sobre atributos de calidad clave como la modificabilidad, el rendimiento y la seguridad, y facilitan la incorporación de nuevos servicios y modelos de IA en el futuro. Finalmente, el epígrafe de reutilización y administración de la configuración completó la visión del capítulo al abordar el ciclo de vida del software: se definieron estrategias explícitas de reutilización de arquitectura, servicios, datos y modelos, y se describieron prácticas de control de versiones, integración y rastreo de incidencias que garantizan trazabilidad y reproducibilidad. Esto es especialmente relevante en un entorno donde los modelos de IA y los datos evolucionan con el tiempo, y donde se prevé que el gemelo digital sirva como plataforma de experimentación y base para nuevos proyectos.

Capítulo 3. Resultados, validación y análisis de modelos

El capítulo 2 definió la arquitectura, los principios de diseño y la organización modular del gemelo digital web, mostrando cómo los servicios de analítica e inteligencia artificial

se integran con los módulos de telemetría, inventario y visualización para apoyar la operación de la microrred fotovoltaica aislada. Sobre esa base, el presente capítulo se centra en evaluar empíricamente el desempeño de los modelos de aprendizaje automático implementados, analizando su capacidad para aportar valor real al gemelo digital. En particular, se validan tres componentes clave:

- el modelo de clasificación del estado de limpieza de los paneles fotovoltaicos a partir de imágenes,
- el modelo de predicción de generación solar basado en variables climáticas, y
- el modelo de predicción de consumo energético universitario a partir de patrones temporales.

Cada uno de estos modelos se evalúa mediante métricas cuantitativas, análisis visuales y una interpretación crítica de sus resultados, con el fin de determinar su idoneidad para su integración en el gemelo digital y de identificar líneas de mejora futura.


3.1 Validación del modelo de clasificación y estimación de suciedad en paneles solares

Para evaluar el desempeño del modelo de clasificación de suciedad en paneles solares, se llevó a cabo un proceso de validación que combinó métricas cuantitativas y análisis visuales. El objetivo del modelo es determinar, a partir de una imagen de módulos fotovoltaicos, si estos se encuentran limpios o sucios, estimando además la probabilidad asociada a cada clase. Este enfoque se alinea con trabajos recientes que emplean redes neuronales convolucionales para la detección de suciedad y polvo en paneles FV, con resultados competitivos en precisión y utilidad para el mantenimiento predictivo. A continuación, se presentan los principales resultados obtenidos.

3.1.1 Ejemplos de predicciones del modelo


En la Figura se muestran predicciones representativas sobre el conjunto de validación. Cada muestra incluye: la etiqueta real (True) del estado del panel y la predicción del modelo (Pred), acompañada del porcentaje de confianza para la clase estimada.

Estas imágenes permiten comprobar que el modelo identifica patrones visuales asociados a la acumulación de polvo, cambios en la reflectancia, variaciones de iluminación y ángulos de captura, distinguiendo en la mayoría de los casos entre paneles limpios y sucios. En los ejemplos también se observan algunos errores de clasificación, especialmente cuando la suciedad es leve o se combina con reflejos intensos y sombras que introducen ambigüedad visual. No obstante, el comportamiento global se mantiene satisfactorio y coherente con lo esperado para un modelo de visión artificial aplicado al monitoreo fotovoltaico.



superior al de un clasificador aleatorio ($AUC = 0.5$) y consistente con un comportamiento discriminativo adecuado entre paneles limpios y sucios. Un AUC cercano a 1 indica que el modelo es capaz de distinguir correctamente la mayoría de las muestras a través de

un amplio rango de umbrales. En este caso, el valor obtenido confirma la solidez del enfoque y respalda su uso como componente de apoyo en sistemas de monitoreo y mantenimiento de instalaciones fotovoltaicas.




alcanzando valores cercanos al 78 % en validación. Esto indica una mejora consistente del modelo sin evidencias marcadas de sobreajuste.

- **Pérdida:** la pérdida de entrenamiento disminuye de manera continua, mientras que la de validación se mantiene estable. La brecha entre ambas curvas es moderada, lo que sugiere buena capacidad de generalización.
- **AUC:** la métrica se incrementa de forma notable en las primeras épocas y supera 0.87 en validación, lo que confirma una adecuada separación entre las dos clases.

En conjunto, estas curvas reflejan un proceso de entrenamiento estable y un desempeño robusto, coherente con lo esperado en modelos basados en redes convolucionales bien regularizadas.

3.1.4 Interpretación general de los resultados

Los resultados obtenidos permiten concluir que el modelo presenta un buen rendimiento en la clasificación del estado de limpieza de los paneles, tanto desde la perspectiva cuantitativa como cualitativa. El análisis visual muestra que la red neuronal identifica de forma consistente rasgos asociados a la suciedad, mientras que las métricas globales



(accuracy y AUC) respaldan su utilidad en escenarios reales. Con un AUC superior a 0.83 y una exactitud estable durante la validación, el modelo se posiciona como una herramienta confiable para el diagnóstico automático del estado de los paneles solares, con potencial para reducir la frecuencia de inspecciones manuales y apoyar estrategias de mantenimiento predictivo dentro del gemelo digital.

3.2 Validación del modelo de predicción de generación solar con datos climáticos

En esta sección se describe la validación del modelo de regresión desarrollado para estimar la potencia generada (kW) por un sistema fotovoltaico a partir de variables meteorológicas tales como radiación solar, temperatura ambiente, humedad relativa y cobertura de nubes. Para evaluar el rendimiento se compararon cuatro algoritmos de regresión: Linear Regression, Ridge Regression, Random Forest Regression y Gradient Boosting Regression. Este análisis sigue la línea de trabajos recientes que estudian modelos híbridos y basados en árboles para la predicción de generación fotovoltaica, destacando la importancia de capturar relaciones no lineales entre clima y producción. A continuación, se presentan los resultados más relevantes.

3.2.1 Comparación de modelos mediante métricas de error y ajuste

La Figura resume la comparación entre los modelos considerando las métricas de validación más significativas:


- RMSE (Root Mean Squared Error),
- MAE (Mean Absolute Error),
- R^2 (coeficiente de determinación),
- RMSE de validación cruzada (Cross-Validation RMSE).

Los modelos lineales (Linear Regression y Ridge Regression) presentan los errores más elevados, con RMSE superiores a 857 y MAE cercanos a 490. Estos valores confirman que una aproximación puramente lineal no es suficiente para capturar la naturaleza no lineal de la relación entre las variables climáticas y la generación fotovoltaica, tal como señalan diversas revisiones sobre modelos híbridos y de aprendizaje automático para energía solar.

En contraste, los modelos basados en árboles Random Forest y Gradient Boosting logran mejoras significativas:

- Random Forest alcanza el menor RMSE de test (536.859) y el menor MAE (229.121).
- Obtiene el mayor R^2 en test (0.854), lo que indica una alta capacidad explicativa sobre la variabilidad de la generación.
- En validación cruzada, su RMSE (~600) es sensiblemente inferior al de los modelos lineales, demostrando mejor estabilidad y generalización.

Gradient Boosting ofrece resultados competitivos; sin embargo, Random Forest presenta un desempeño superior de forma más consistente en todas las métricas, en línea con otros estudios donde este algoritmo destaca en pronóstico de carga y generación eléctrica.




3.2.2 Evaluación del modelo seleccionado: Random Forest

La Figura recoge dos análisis visuales fundamentales del modelo Random Forest:

Predicción vs. valores reales: los puntos se alinean de forma cercana a la línea de predicción perfecta, especialmente en rangos de generación media y alta. Esto indica que el modelo reproduce adecuadamente las variaciones reales de producción solar, incluso bajo condiciones meteorológicas diversas.

Análisis de residuos: la nube de residuos se distribuye alrededor de cero sin patrones discernibles, lo que sugiere ausencia de sesgos sistemáticos, buen ajuste del modelo a lo largo de diferentes niveles de generación y comportamiento estable sin indicios fuertes de sobreajuste.

Aunque se observa un incremento moderado de la magnitud de los residuos en valores de potencia muy elevados algo habitual en series energéticas, la tendencia general es aceptable para aplicaciones prácticas de monitoreo y soporte a la operación.



3.2.3 Relación entre variables climáticas y generación solar

La Figura muestra diagramas de dispersión que ilustran cómo influyen las variables meteorológicas en la producción energética:

Radiación solar: es la variable más determinante; a mayor radiación, mayor generación, aunque con cierta dispersión causada por otros factores operativos.

Temperatura ambiente: se aprecia una relación creciente moderada, pero temperaturas muy altas reducen la eficiencia fotovoltaica, provocando mayor dispersión en los niveles superiores.

Humedad relativa: tiende a correlacionarse negativamente con la generación debido al aumento de la opacidad atmosférica y la posible presencia de nubosidad densa.

Cobertura de nubes: presenta un patrón inverso, donde una mayor nubosidad implica menor producción, con alta variabilidad según tipo, densidad y dinámica de las nubes.

Este análisis respalda la necesidad de emplear modelos no lineales capaces de capturar interacciones complejas entre variables, tal como se enfatiza en revisiones recientes sobre predicción fotovoltaica basadas en técnicas híbridas y de aprendizaje automático.



3.2.4 Conclusión de la validación de generación

Los resultados obtenidos permiten concluir que Random Forest Regression es el modelo más adecuado para predecir la generación de energía solar a partir de información climática. Sus métricas de error reducidas, su alta capacidad explicativa (R^2) y su estabilidad en validación cruzada lo convierten en la alternativa más robusta entre las evaluadas. Además, su habilidad para modelar relaciones no lineales y manejar interacciones entre múltiples variables meteorológicas respalda su integración dentro del

gemelo digital como servicio de pronóstico de generación, aportando insumos valiosos para la planificación operativa y la gestión de la microrred.

3.3 Validación del modelo de predicción de consumo energético universitario

Este apartado tiene como propósito validar el modelo desarrollado para estimar el consumo eléctrico (kW) de una universidad utilizando información temporal y patrones históricos de demanda. Se evaluaron tres algoritmos: Regresión Lineal, Árbol de Decisión y Random Forest, analizando su rendimiento predictivo, tiempo de entrenamiento y comportamiento visual en distintas representaciones gráficas. Este ejercicio se enmarca en la tendencia a emplear modelos de aprendizaje automático para series de tiempo energéticas, donde la calidad de las variables de entrada y la ingeniería de características resultan determinantes para obtener buenos resultados.

3.3.1 Análisis de predicción vs. valores reales

El análisis del gráfico Predicción vs. Real revela que el modelo Random Forest presenta limitaciones importantes para capturar adecuadamente el comportamiento del consumo energético universitario en su configuración actual. En primer lugar, se identifica un problema crítico en el rango de consumos bajos (0–5 kW): el modelo genera predicciones altamente dispersas y, con frecuencia, sobreestimadas, alcanzando incluso valores superiores a 15 o 20 kW cuando el consumo real es cercano a cero. Esta inconsistencia afecta directamente la fiabilidad de las estimaciones en horas valle como la madrugada, donde se esperaría un patrón más estable y predecible.


En los rangos de consumo medio (5–15 kW), la dispersión sigue siendo elevada: un mismo valor real puede asociarse a predicciones muy diferentes, lo que evidencia una varianza alta y una capacidad limitada del modelo para capturar patrones horarios recurrentes. La aparición de “bandas horizontales” en la nube de puntos sugiere, además, que el modelo tiende a repetir ciertos valores frecuentes (por ejemplo, alrededor de 15 kW), reflejando que no está aprendiendo una relación rica entre las características temporales y la demanda, sino aproximando promedios del conjunto de entrenamiento. Estas observaciones indican que, con las características actualmente empleadas

principalmente fecha y hora, el modelo no logra capturar la dinámica real del consumo universitario. La demanda energética depende de factores más complejos: calendario académico, actividad laboral, uso de laboratorios, afluencia estudiantil, temperatura e iluminación ambiental, uso de climatización y eventos extraordinarios, entre otros.

Sin variables que representen explícitamente estos patrones operativos, es esperable que incluso modelos no lineales se comporten de forma errática y produzcan predicciones inestables. Por ello, para mejorar significativamente el rendimiento se requiere enriquecer el conjunto de datos incorporando variables adicionales, tales como:

- indicadores de día lectivo/no lectivo,
- tipo de jornada y periodo académico,
- temperatura y condiciones ambientales,
- uso histórico por edificios o zonas,
- carga base nocturna,
- perfiles diferenciados de fin de semana,
- fechas especiales y eventos relevantes.

Solo mediante este enriquecimiento contextual el modelo podrá aprender patrones más cercanos al comportamiento real y ofrecer estimaciones horarias consistentes y fiables.



En la Figura se presenta la comparación entre los tres modelos evaluados.

R² (test)

Los tres modelos obtienen valores negativos de R², lo que indica que ninguno logra explicar adecuadamente la varianza del consumo con las características actuales. No obstante, se observan diferencias relativas:

- Random Forest presenta el R² menos negativo y, por tanto, el mejor desempeño dentro del conjunto.
- La Regresión Lineal muestra el peor ajuste, probablemente debido a la marcada no linealidad de los patrones de uso energético universitario [18][20][46].

MAE (test)

En cuanto al error absoluto medio:

- Random Forest y Árbol de Decisión alcanzan los mejores valores de MAE (~8 kW).


- La Regresión Lineal presenta un MAE considerablemente mayor (~12 kW), lo que refuerza su inadecuación para este problema.

Tiempo de entrenamiento

Tal como es esperable:

- Random Forest es el modelo con mayor costo computacional, debido a la construcción de múltiples árboles.
- La Regresión Lineal tiene un tiempo de entrenamiento prácticamente instantáneo.
- El Árbol de Decisión ocupa una posición intermedia.

Estos resultados reflejan el compromiso habitual entre precisión y costo computacional: aunque Random Forest demanda más recursos, ofrece el comportamiento más robusto dentro del conjunto analizado.




3.3.3 Predicción horaria de consumo

La Figura muestra la predicción promedio por hora del día utilizando el modelo Random Forest. Los resultados describen un patrón razonablemente coherente con el funcionamiento típico de una universidad:

- Horas tempranas (00:00–07:00): bajo consumo, asociado a la mínima actividad en instalaciones.
- Incremento progresivo (08:00–12:00): coincide con el inicio de clases, apertura de edificios y aumento de la carga operativa en aulas y oficinas.
- Pico máximo alrededor de 11:00–14:00: periodo de mayor actividad académica y uso intensivo de laboratorios, equipos de cómputo y climatización.
- Descenso después de las 17:00 y estabilización nocturna: ligado al cierre de oficinas y a la reducción del uso de aulas y espacios comunes.

La línea roja punteada indica el consumo promedio general (≈ 14.44 kW), lo que facilita comparar qué horas están por encima o por debajo del comportamiento estándar, y sirve como referencia para detectar posibles desviaciones anómalas.



3.3.4 Conclusión general sobre el modelo de consumo

Dentro del conjunto de modelos evaluados, Random Forest se confirma como la opción relativamente más adecuada para predecir el consumo energético universitario, gracias a su capacidad para modelar relaciones no lineales y su mejor desempeño en términos de MAE y R^2 , pese a las limitaciones de los datos disponibles. Sin embargo, los resultados también evidencian que la calidad y riqueza del conjunto de características es el factor crítico: sin variables que describan el contexto operativo (calendario académico, ocupación, condiciones ambientales), incluso los modelos avanzados ofrecen un ajuste limitado. En este sentido, el modelo actual debe entenderse como una línea base sobre la cual construir versiones mejoradas, apoyadas en nuevas fuentes de datos y una ingeniería de características más profunda. Aun con estas restricciones, el modelo proporciona una primera aproximación útil para explorar patrones horarios de demanda y abre la puerta a aplicaciones posteriores como detección de anomalías, ajuste y desplazamiento de cargas y planificación de estrategias de eficiencia energética en el campus.

3.4 Conclusiones generales del capítulo 3

Este capítulo permitió validar y analizar en detalle los modelos desarrollados para los distintos componentes del sistema: la clasificación del estado de limpieza de paneles solares a partir de imágenes, la predicción de generación fotovoltaica basada en variables climáticas y la estimación del consumo energético universitario mediante información temporal. En conjunto, estos experimentos ofrecen una visión integral del comportamiento, las capacidades y las limitaciones de las técnicas de aprendizaje automático aplicadas al contexto energético abordado. En primer lugar, el modelo de clasificación de limpieza de paneles mostró un desempeño sólido, con un AUC superior a 0.83 y una precisión estable en validación. El análisis visual evidenció que la red distingue con consistencia entre paneles limpios y sucios, incluso ante variaciones de iluminación, ángulo y brillo. Estos resultados confirman que el uso de redes convolucionales para la detección de suciedad en módulos fotovoltaicos tiene un gran

potencial para automatizar el monitoreo del estado de los paneles y reducir la necesidad de inspecciones manuales.

En segundo lugar, los modelos desarrollados para predecir la generación fotovoltaica demostraron de manera clara la superioridad de los enfoques no lineales frente a los lineales. El modelo Random Forest destacó en prácticamente todas las métricas, con menores errores de predicción (RMSE y MAE), mayor capacidad de ajuste (R^2) y mejor estabilidad en validación cruzada. Este comportamiento se relaciona con la naturaleza no lineal y multivariable del problema, donde la generación depende de interacciones complejas entre radiación solar, temperatura, humedad relativa y nubosidad. Los modelos basados en árboles resultan especialmente adecuados para capturar dichas relaciones, tal como refuerzan estudios recientes en predicción de recursos renovables. En tercer lugar, la validación del modelo de predicción de consumo energético universitario puso de manifiesto las limitaciones asociadas a conjuntos de datos con pocas variables explicativas. A diferencia de los casos anteriores, aquí la información disponible centrada en fecha, hora y consumo histórico no es suficiente para caracterizar la complejidad del uso energético de una institución académica. El análisis predicción vs. real mostró inconsistencias significativas, alta varianza y dificultades para diferenciar entre periodos de alta y baja demanda. Esta situación refuerza la idea, ampliamente documentada en la literatura de pronóstico energético y MLOps, de que la calidad y riqueza de los datos es tan importante como la elección del modelo.

En términos globales, este capítulo permite extraer tres ideas clave: Los modelos ofrecen resultados satisfactorios cuando las variables de entrada capturan adecuadamente la dinámica del fenómeno, como en el caso de la visión por computadora y la predicción de generación solar. La falta de contexto y de atributos representativos limita el desempeño de cualquier algoritmo, independientemente de su complejidad, como se observó en el escenario de consumo universitario. La integración de estos modelos dentro del gemelo digital fortalece su capacidad para diagnosticar, predecir y apoyar decisiones de operación y mantenimiento en la microrred fotovoltaica aislada. En síntesis, mientras los modelos de clasificación de limpieza y de predicción de generación alcanzan un nivel de madurez que los habilita para ser utilizados en aplicaciones reales de monitoreo y

soporte a la operación, el modelo de consumo requiere un trabajo adicional en ingeniería de datos y ampliación de fuentes de información. Esta conclusión abre una línea clara de mejora para trabajos futuros, orientada a incorporar variables contextuales y operativas que permitan captar con mayor fidelidad los patrones de demanda energética universitaria y, en consecuencia, diseñar estrategias más eficaces de planificación y eficiencia energética.

CONCLUSIONES GENERALES

El análisis del contexto energético nacional y de la literatura internacional permitió confirmar que las microrredes fotovoltaicas aisladas con almacenamiento constituyen una alternativa técnica y económicamente viable frente a esquemas basados en grupos electrógenos diésel, al reducir el costo nivelado de la energía, la dependencia de combustibles importados y la vulnerabilidad ante eventos extremos. La revisión de los fundamentos teóricos evidenció que el gemelo digital, concebido como una representación virtual sincronizada con el sistema físico, constituye un habilitador clave para cerrar el ciclo medir–predecir–actuar en microrredes, integrando tecnología de sensores, comunicaciones IoT, modelos de datos e inteligencia artificial para el monitoreo, el diagnóstico temprano y la optimización operativa. El estudio crítico del estado del arte de plataformas comerciales, herramientas de simulación y stacks tecnológicos open-source puso de manifiesto patrones arquitectónicos recurrentes (ingesta IoT, bases de datos de series temporales, dashboards web y motor de IA), así como brechas específicas para el contexto cubano relacionadas con costos de licencia, dependencia de hardware propietario y restricciones de conectividad, lo que justificó la elección de una solución auto hospedable basada en tecnologías abiertas.

El diseño arquitectónico del gemelo digital web, estructurado como un monolito modular cliente–servidor y soportado en estilos y patrones bien establecidos (cliente–servidor, n-capas, repositorio, tuberías y filtros, SOLID, GRASP y patrones GoF), permitió satisfacer los requisitos funcionales y no funcionales definidos, favoreciendo atributos de calidad como mantenibilidad, extensibilidad, portabilidad y seguridad básicos, adecuados al entorno universitario y de laboratorio. La implementación de los modelos de inteligencia artificial integrados al gemelo digital demostró que los enfoques basados en redes convolucionales y modelos de árboles de decisión en conjunto, resultan adecuados para tareas de clasificación y regresión en el dominio fotovoltaico: el clasificador de suciedad en paneles alcanzó un desempeño robusto (AUC y exactitud estables) y el modelo Random Forest de generación mostró bajos errores y alta capacidad explicativa, aportando valor real al soporte de decisiones operativas.

La validación del modelo de consumo energético universitario puso en evidencia que la calidad y riqueza de las variables de entrada son determinantes para el desempeño de los algoritmos: con un conjunto de características limitado a información temporal, incluso modelos avanzados ofrecieron un ajuste insuficiente, lo que señala la necesidad de incorporar datos contextuales (calendario académico, ocupación, clima, uso de instalaciones) para mejorar la capacidad predictiva. El prototipo funcional del gemelo digital web integró en una única plataforma las capacidades de monitoreo, visualización, predicción y estimación de autonomía de la microrred, demostrando la factibilidad técnica de la solución y su potencial como herramienta de apoyo a la operación, la docencia y la investigación en el ámbito de las microrredes fotovoltaicas aisladas en la CUJAE.

RECOMENDACIONES

1. Profundizar en la integración de la plataforma con una microrred fotovoltaica real o banco de pruebas experimental de la CUJAE, incorporando telemetría en tiempo real y ciclos de prueba controlados que permitan validar el gemelo digital en condiciones de operación más cercanas al entorno productivo.
2. Enriquecer el modelo de predicción de consumo energético mediante la incorporación de nuevas fuentes de datos (calendario académico, registros de ocupación de aulas y laboratorios, uso de climatización, variables climáticas locales), así como explorar arquitecturas específicas para series temporales (LSTM, modelos híbridos físico–datos) que mejoren el ajuste y la capacidad de generalización.
3. Extender las funcionalidades de mantenimiento predictivo del gemelo digital, incorporando modelos adicionales para detección de anomalías en inversores, strings y bancos de baterías, y ampliando el uso de visión por computador hacia otros tipos de defectos en módulos fotovoltaicos (sombreado parcial, hot-spots, degradación mecánica).
4. Formalizar prácticas de gobierno del dato y MLOps alrededor de los modelos desplegados, incluyendo monitoreo continuo de métricas de desempeño, detección de deriva de datos y concepto, políticas de reentrenamiento periódico y registro sistemático de versiones de modelos y conjuntos de datos, de modo que se garantice la trazabilidad y reproducibilidad de los resultados.
5. Evaluar la escalabilidad de la arquitectura propuesta hacia escenarios con mayor número de puntos de medición y múltiples microrredes, analizando alternativas como la evolución hacia arquitecturas basadas en servicios o la integración con herramientas de simulación y planificación (GridLAB-D, HOMER, OpenDSS) para cerrar el ciclo diseño–operación–análisis dentro del gemelo digital.
6. Explorar el uso del gemelo digital como recurso docente y de investigación en asignaturas de energías renovables, redes inteligentes e inteligencia artificial aplicada, diseñando prácticas y proyectos que aprovechen la plataforma para que

estudiantes y profesores experimenten con escenarios de operación, estrategias de control y nuevos modelos de análisis.

Referencias Bibliográficas

- [1] International Energy Agency, «Islands need resilient power systems more than ever: Clean energy can deliver». [En línea]. Disponible en: <https://www.iea.org/>
- [2] U.S. Department of Energy, «Powering the Blue Economy: Exploring Opportunities for Marine Renewable Energy in Maritime Markets—Community Scale Isolated Power Systems», U.S. Department of Energy, Washington, DC, USA, 2019.
- [3] International Renewable Energy Agency, «Renewable Power Generation Costs in 2024», IRENA, Abu Dhabi, UAE, jul. 2025. [En línea]. Disponible en: <https://www.irena.org/>
- [4] A. B. Nassif y others, «Valuing resilience benefits of microgrids for an interconnected island distribution system», *Electronics*, vol. 11, p. 4206, 2022, doi: 10.3390/electronics11244206.
- [5] B. R. Barricelli, E. Casiraghi, y D. Fogli, «A survey on digital twin: Definitions, characteristics, applications, and design implications», *IEEE Access*, vol. 7, pp. 167653-167671, 2019, doi: 10.1109/ACCESS.2019.2953499.
- [6] A. A. A. Ardebili y others, «Digital twins of smart energy systems: A systematic literature review on enablers, design, management and computational challenges», *Energy Inform.*, vol. 7, p. 94, 2024, doi: 10.1186/s42162-024-00385-5.
- [7] D. D. Angelova y others, «A review on digital twins and its application in the modeling of photovoltaic installations», *Energies*, vol. 17, n.º 5, p. 1227, 2024, doi: 10.3390/en17051227.
- [8] S. Al Dahidi y others, «Forecasting solar photovoltaic power production: A comprehensive review and innovative data driven modeling framework», *Energies*, vol. 17, n.º 16, p. 4145, 2024, doi: 10.3390/en17164145.
- [9] Y. Ledmaoui y others, «Review of recent advances in predictive maintenance and cybersecurity for solar plants», *Sensors*, vol. 25, n.º 1, p. 206, 2025, doi: 10.3390/s25010206.
- [10] D. Narang y others, «Overview of Functional Technical Requirements for Intentional Islands (Referencing IEEE 2030.7)», NREL, Golden, CO, USA, NREL/TP-5D00-83301, 2022.
- [11] X. Li y others, «Performance Monitoring of African Micro Grids: Good Practices and Operational Data», NREL, Golden, CO, USA, NREL/TP-7A40-71767, 2020.

- [12] M. Ingram, T. Ryan, y R. Shepard, «Microgrids 101», NREL, Golden, CO, USA, 2025. [En línea]. Disponible en: <https://www.nrel.gov/>
- [13] U.S. Department of Energy, «Microgrid Overview: Grid Resilience Formula Grants (40101d) – Fact Sheet», U.S. Department of Energy, Washington, DC, USA, 2024. [En línea]. Disponible en: <https://www.energy.gov/>
- [14] Y. Martínez Lopez y others, «Algoritmos evolutivos aplicados a la gestión de las unidades generadoras de la microred eléctrica de Cayo Coco», *Rev. Cuba. Transform. Digit.*, vol. 4, n.º 4, p. e232, 2023.
- [15] D. Sherwood y M. Frank, «Cuba on track to install 50 solar parks this year, ministry says». [En línea]. Disponible en: <https://www.reuters.com/>
- [16] J. Vickers, «The promise and applications of digital twins». [En línea]. Disponible en: <https://ntrs.nasa.gov/>
- [17] M. Grieves, *Digital Twin: Manufacturing Excellence Through Virtual Factory Replication*. Digital Twin Institute, 2014.
- [18] L. de Oliveira Santos y others, «Photovoltaic power estimation and forecast models integrating physics and machine learning: A review on hybrid techniques», *Sol. Energy*, vol. 284, p. 113044, 2024, doi: 10.1016/j.solener.2024.113044.
- [19] Q. Wang y others, «Quantifying the value of probabilistic forecasting for power system operations», *Appl. Energy*, vol. 343, p. 121254, 2023, doi: 10.1016/j.apenergy.2023.121254.
- [20] J. Im, J. Kim, y Y. Park, «An end-to-end data and machine learning pipeline for energy forecasting: A practical MLOps approach», *Information*, vol. 16, n.º 9, p. 805, 2025, doi: 10.3390/info16090805.
- [21] J. S. Stein, M. Theristis, y A. Driesse, «PV Performance Modeling Methods and Practices», IEA PVPS/PVPMC, IEA PVPS T13-06, 2017.
- [22] W. Holmgren y others, «Solar Forecast Arbiter: Open-source Evaluation Framework». EPRI/DOE, 2019.
- [23] A. Singh y others, «A systematic review of reinforcement learning based microgrid control», *SN Appl. Sci.*, 2025, doi: 10.1007/s42452-025-07529-6.
- [24] Huawei Digital Power Technologies Co., Ltd., «FusionSolar app overview». [En línea]. Disponible en: <https://la5.fusionsolar.huawei.com/fusionsolarapp>

- [25] Huawei Digital Power Technologies Co., Ltd., «FusionSolar Smart PV Management System (SmartPVMS) – Overview and User Manuals». [En línea]. Disponible en: <https://support.huawei.com>
- [26] ABB, «ABB Ability™ Energy Manager – Smart power digital solution». [En línea]. Disponible en: <https://new.abb.com/low-voltage/products/smart-power-digital-solutions/abb-ability-energy-manager>
- [27] Siemens AG, «Spectrum Power™ 5 – Efficient power grid management for small and mid-size grids». [En línea]. Disponible en: <https://www.siemens.com/global/en/products/energy/grid-software/operation/spectrum-power-5.html>
- [28] Pacific Northwest National Laboratory, «GridLAB-D™ – Power distribution system simulation and analysis tool». [En línea]. Disponible en: <https://www.pnnl.gov/available-technologies/gridlab-dtm>
- [29] UL Solutions, «HOMER® microgrid and hybrid power modeling software». [En línea]. Disponible en: <https://www.ul.com/software/ultrus/homer-microgrid-and-hybrid-power-modeling-software>
- [30] Electric Power Research Institute (EPRI), «Introduction to OpenDSS – The Open-Source Distribution System Simulator». [En línea]. Disponible en: <https://opendss.epri.com>
- [31] ThingsBoard Authors, «ThingsBoard — Open-source IoT platform». [En línea]. Disponible en: <https://thingsboard.io>
- [32] Grafana Labs, «Time series visualizations in Grafana». [En línea]. Disponible en: <https://grafana.com/docs/grafana/latest/panels-visualizations/visualizations/time-series/>
- [33] InfluxData, «InfluxDB time series data platform overview». [En línea]. Disponible en: <https://www.influxdata.com/products/influxdb-overview/>
- [34] TensorFlow Authors, «TensorFlow: An end-to-end open source platform for machine learning». [En línea]. Disponible en: <https://www.tensorflow.org>
- [35] Vercel, «Next.js by Vercel – The React Framework for the web». [En línea]. Disponible en: <https://nextjs.org>
- [36] S. Ramírez y others, «FastAPI – Modern, fast (high-performance) web framework for building APIs with Python». [En línea]. Disponible en: <https://fastapi.tiangolo.com>

- [37] GraphQL Foundation, «GraphQL: A query language for your API». [En línea]. Disponible en: <https://graphql.org>
- [38] MongoDB Inc., «Time Series – Native time series collections in MongoDB». [En línea]. Disponible en: <https://www.mongodb.com/products/capabilities/time-series>
- [39] F. Pedregosa y others, «Scikit-learn: Machine learning in Python», *J. Mach. Learn. Res.*, vol. 12, pp. 2825-2830, 2011.
- [40] Open-Meteo, «Satellite Radiation API – Solar radiation from geostationary satellites». [En línea]. Disponible en: <https://open-meteo.com/en/docs/satellite-radiation-api>
- [41] G. Gagliardi y others, «Towards Energy Efficiency of HPC Data Centers: A Data-Driven Analytical Framework with a Digital Twin», *Electronics*, vol. 14, n.º 16, p. 3170, 2025, doi: 10.3390/electronics14163170.
- [42] Microsoft Azure, «Algoritmos de aprendizaje automático». [En línea]. Disponible en: <https://azure.microsoft.com/es-es/resources/cloud-computing-dictionary/what-are-machine-learning-algorithms/>
- [43] T. V. Hoang, H.-T. T. Nguyen, M.-H. T. Nguyen, y V.-H. Bui, «Solar Radiation Forecasting Based on Random Forest and XGBoost», en *2024 7th International Conference on Green Technology and Sustainable Development (GTSD)*, 2024, pp. 1-6. doi: 10.1109/GTSD10674.2024.10674955.
- [44] L. Breiman, «Random Forests», *Mach. Learn.*, vol. 45, n.º 1, pp. 5-32, 2001, doi: 10.1023/A:1010933404324.
- [45] W. L. Dudek, «A Comprehensive Study of Random Forest for Short-Term Load Forecasting», *Energies*, vol. 15, n.º 20, p. 7547, oct. 2022, doi: 10.3390/en15207547.
- [46] Google Cloud, «¿Qué es una red neuronal convolucional?» [En línea]. Disponible en: <https://cloud.google.com/discover/what-are-convolutional-networks?hl=es>
- [47] M. R, A. L, y S. T, «Modified Convolutional Neural Network Algorithm for Categorization of Solar PV Panel Soiling», en *2024 International Conference on Intelligent Systems and Signal Processing (ISSP)*, 2024, pp. 1-6. doi: 10.1109/ISSP10537.2024.10537299.
- [48] B. S. Evstatiev y D. N. Trifonov, «PV Module Soiling Detection Using Visible Spectrum Imaging and Machine Learning», en *2023 15th Electrical Engineering Faculty Conference (BulEF)*, 2023, pp. 1-5. doi: 10.1109/BulEF58807.2023.10389334.

- [49] M. S. H. Onim y others, «SolNet: A Convolutional Neural Network for Detecting Dust on Solar Panels», *Energies*, vol. 16, n.º 1, p. 155, 2023, doi: 10.3390/en16010155.
- [50] ISO/IEC, «ISO/IEC 25010:2023, Systems and Software Engineering — Systems and Software Quality Requirements and Evaluation (SQuaRE) — Product Quality Model», International Organization for Standardization, Geneva, Switzerland, 2023. [En línea]. Disponible en: <https://www.iso.org/standard/78176.html>
- [51] Apriorit, «Writing Clear Functional and Non-functional Requirements: Tips and Best Practices from Apriorit Experts». [En línea]. Disponible en: <https://www.apriorit.com/dev-blog/creating-clear-functional-and-non-functional-requirements>
- [52] P. Kruchten, «Architectural Blueprints—The ‘4+1’ View Model of Software Architecture», *IEEE Softw.*, vol. 12, n.º 6, pp. 42-50, 1995.
- [53] Pretius, «Modular software architecture 101: Modular monolith vs microservices». [En línea]. Disponible en: <https://pretius.com/blog/modular-software-architecture>
- [54] Encyclopedia Britannica, «Client-server architecture». [En línea]. Disponible en: <https://www.britannica.com/technology/client-server-architecture>
- [55] Refactoring.Guru, «Refactorización y patrones de diseño». [En línea]. Disponible en: <https://refactoring.guru/es>
- [56] E. Gamma, R. Helm, R. Johnson, y J. Vlissides, *Design Patterns: Elements of Reusable Object-Oriented Software*. Reading, MA, USA: Addison-Wesley, 1994. [En línea]. Disponible en: <https://www.oreilly.com/library/view/design-patterns-elements/0201633612/>
- [57] DigitalOcean, «SOLID Design Principles Explained: Building Better Software». [En línea]. Disponible en: <https://www.digitalocean.com/community/conceptual-articles/s-o-l-i-d-the-first-five-principles-of-object-oriented-design>

Glosario de Siglas:

Sigla	Definición
DT	Digital Twin, gemelo digital
EMS	Sistema de Gestión de Energía
SCADA	Supervisión, Control y Adquisición de Datos
DER	Recursos Energéticos Distribuidos
FV	Fotovoltaica
LCOE	Costo Nivelado de la Energía
KPI	Indicador Clave de Desempeño
MPC	Control Predictivo Basado en Modelo
DRL	Aprendizaje por Refuerzo Profundo
SoC	Estado de Carga de la batería
CRPS	Continuous Ranked Probability Score

Tabla 1. Glosario de siglas.